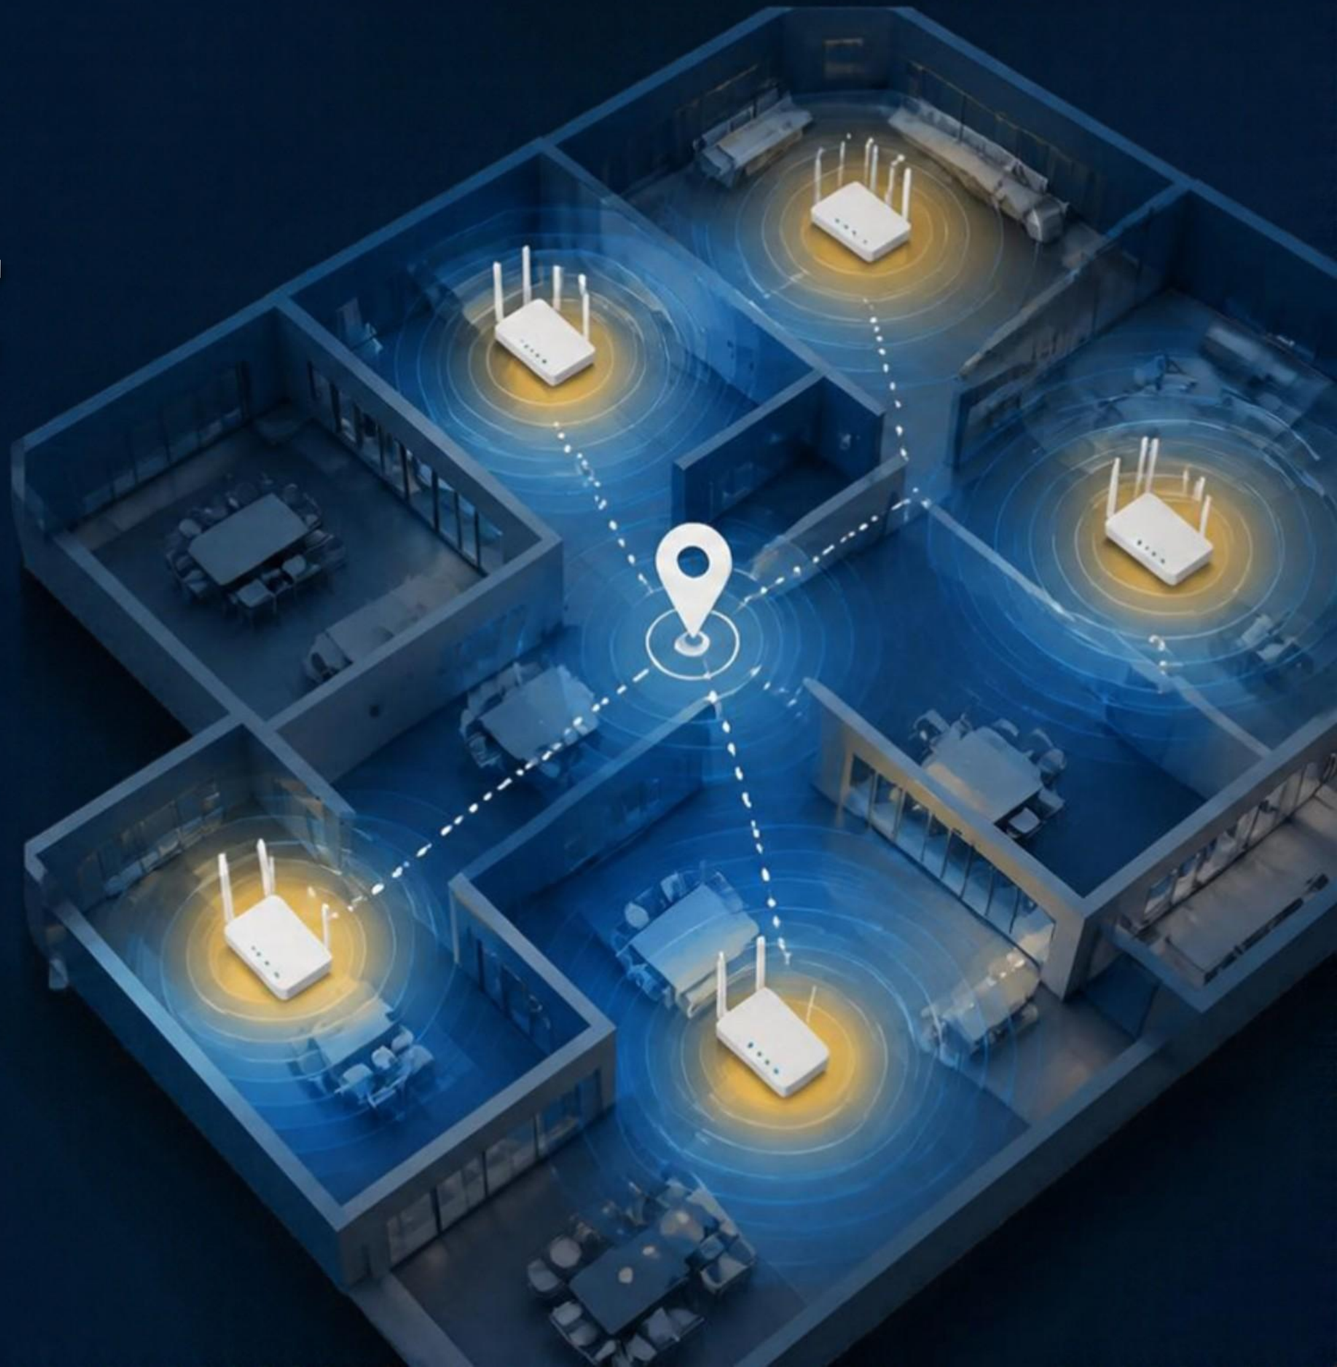
High Utility Itemset Mining (HUIM)

Ứng dụng chọn Access Point cho định vị trong nhà bằng vân tay Wi-Fi — thực nghiệm trên UJIIndoorLoc

VERSION 2 · cập nhật 13/10/2026

Thay thế Version 1 (bản Canva ngày 08/10/2026). Mọi số liệu sinh tự động từ results/ của dự án.



Version 2 có gì mới?

So với bản trình bày Version 1 (PDF Canva ngày 08/10/2026, 22 trang) — số liệu trên 1.111 fingerprint của validationData

Sai số trung bình

9,28 → 5,36 m

mét thực địa

Sai số trung vị

4,61 → 3,52 m

mét thực địa

Độ chính xác tòa nhà + tầng

87,76% → 94,69%

joint accuracy

Fingerprint sai số ≤ 8 m

69,5% → 80,5%

tỉ lệ trên tập kiểm định

GIỮ NGUYÊN TỪ VERSION 1

- Dữ liệu UJIIndoorLoc, ánh xạ HUIM ↔ IPS, q(i,T) và ba mô hình p(i)
- EFIM và 37 lần khai phá; 190 điều kiện đánh giá IPS
- Giao thức chống rò rỉ: mọi tham số học trên trainingData
- Kết luận về HUIM: tập WAP do HUIM chọn vẫn thua top-n theo MI

THAY ĐỔI VÀ BỔ SUNG

- Bộ ước lượng toạ độ mới: exponential + Bray-Curtis, k = 12, $w = 1/d^4$, dò lệch ±6 dB, ensemble
- Chọn mô hình trên 6 fold giữ lại người đo (GroupKFold theo USERID)
- Kiểm chứng độc lập: 28 phép HUIM, 24 phép định vị, Excel tính tay
- Mọi công thức ghi rõ tác giả / nguồn; đính chính 8 chỗ sai của slide V1
- Biểu đồ vẽ lại, in minUtil; số theo định dạng Việt Nam (1.234,56)

HUIM là gì?

High Utility Itemset Mining **(HUIM)**: tìm các tập mục có **tổng utility cao** — kết hợp số lượng và giá trị của từng mục.

Khác Frequent Itemset Mining chỉ đếm tần suất xuất hiện, HUIM ưu tiên giá trị mang lại.

Ví dụ siêu thị

nhiều chai nước suối → lời thấp mỗi chai

1 chai nước hoa → lời cao

FREQUENT ITEMSET MINING		HIGH UTILITY ITEMSET MINING
Tập mục xuất hiện nhiều lần	MỤC TIÊU →	Tập mục có tổng utility cao
sup(X) ≥ minSup	TIÊU CHÍ →	u(X) ≥ minUtil
Phổ biến nhưng có thể lợi nhuận thấp	KẾT QUẢ →	Ít phổ biến nhưng lợi nhuận cao
Bánh mì & sữa (rất thường xuyên)	VÍ DỤ →	Rượu vang & phô mai (ít nhưng lời cao)

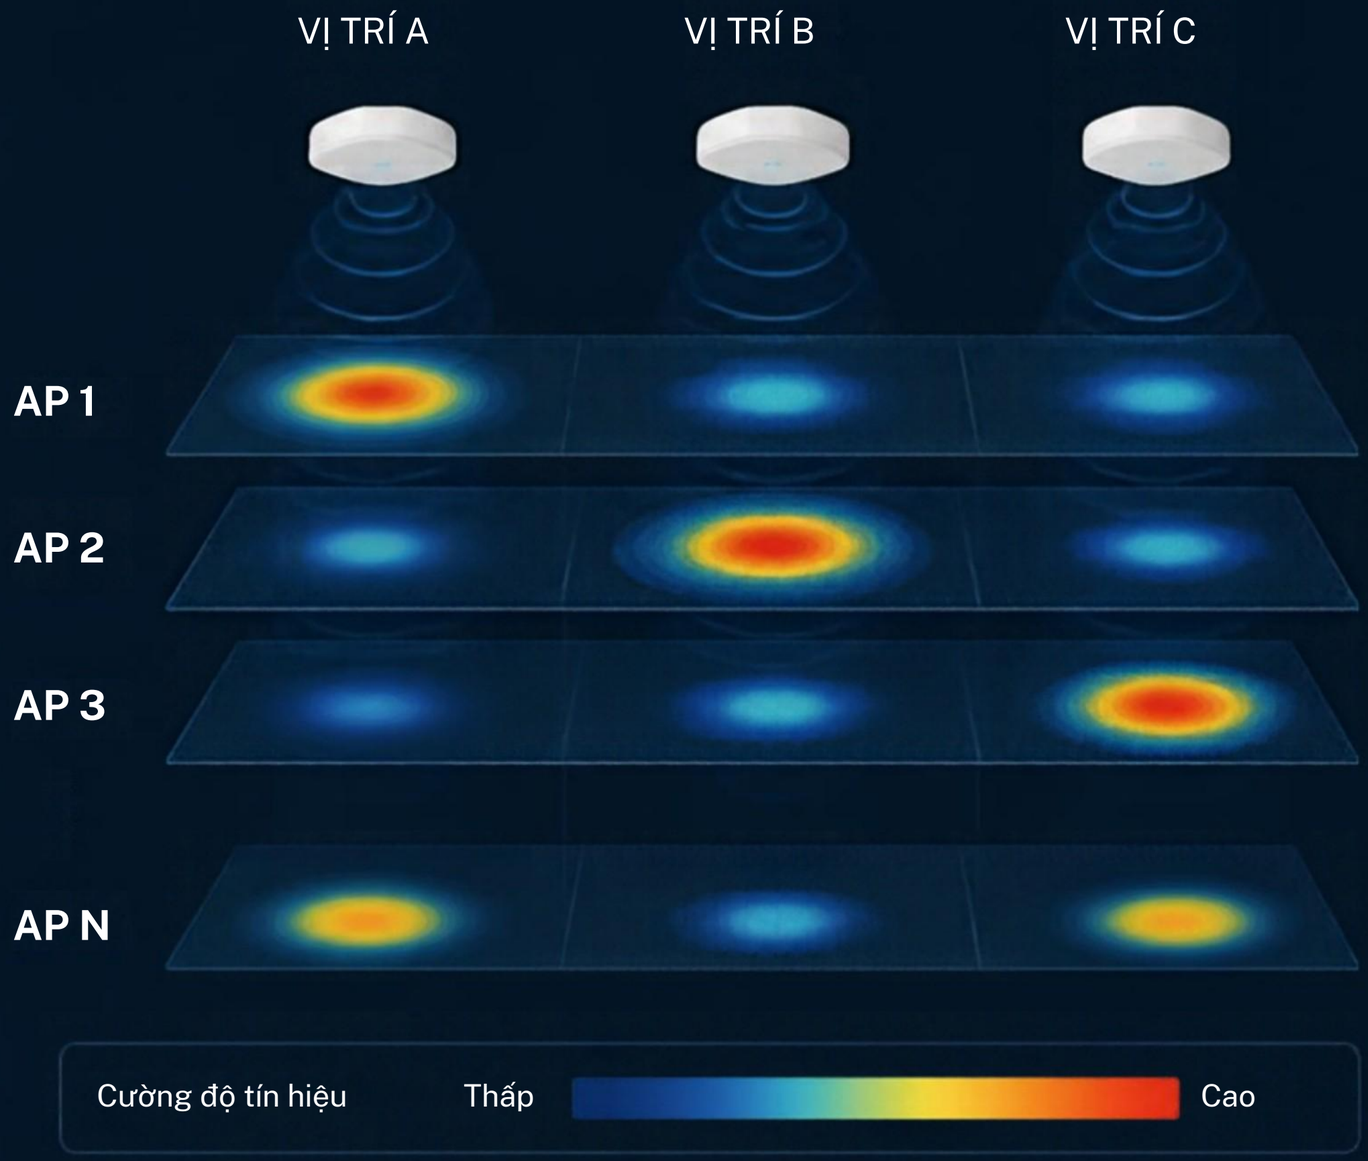
Nguồn: FIM — Agrawal, Imieliński & Swami, SIGMOD 1993 [1]; HUIM — Yao, Hamilton & Butz, SDM 2004 [2]

HUIM và Hệ thống Định vị Trong nhà (IPS)

Wi-Fi fingerprinting ghi cường độ tín hiệu (RSSI) từ nhiều AP tại các vị trí đã biết.

Số AP rất lớn (**520** cột WAP) nhưng không phải AP nào cũng hữu ích cho định vị.

Câu hỏi: nhóm AP có **tổng utility cao** do HUIM tìm ra có phải tập đặc trưng tốt? — trả lời bằng thực nghiệm có đối chứng.



Định nghĩa toán học của HUIM

1 · Utility của mục và của tập mục

$$u(i, T) = q(i, T) \cdot p(i) \qquad u(X, T) = \sum_{i \in X} u(i, T)$$

$$u(X) = \sum_{T \in D,\ X \subseteq T} u(X, T)$$

q: lượng (utility nội) · p: giá trị đơn vị (utility ngoài)

Nguồn: Yao, Hamilton & Butz, SDM 2004 [2]; tổng quan Gan et al., IEEE TKDE 2021 [3]

2 · Tập hữu ích cao (HUI) và minUtil

$$X \in \text{HUIs} \Leftrightarrow u(X) \geq \text{minUtil}$$

$$\text{minUtil} = \theta \cdot \sum_{T \in D} \text{TU}(T)$$

θ theo % vì tổng utility chênh 2,08 lần giữa ba mô hình p(i)

Nguồn: HUI — Yao, Hamilton & Butz, SDM 2004 [2]; θ theo % tổng utility — quy ước của bài tìm hiểu

3 · Cận trên TWU (phản đơn điệu)

$$\text{TU}(T) = \sum_{i \in T} u(i, T)$$

$$\text{TWU}(X) = \sum_{T \supseteq X} \text{TU}(T) \ \geq \ u(Y) \quad \forall\, Y \supseteq X$$

TWU < minUtil ⇒ loại X và mọi tập chứa X

Nguồn: Liu, Liao & Choudhary, PAKDD 2005 [4]

4 · Độ hỗ trợ (Frequent Itemset Mining)

$$\sup(X) = |\{\, T \in D :\ X \subseteq T \,\}|$$

FIM coi mọi mục ngang nhau; HUIM thêm lượng q và giá trị p

Nguồn: Agrawal, Imieliński & Swami, SIGMOD 1993 [1]

Utility không đơn điệu (ví dụ chuẩn của EFIM [5]): u({b}) = 16 < u({b,d}) = 30 nhưng u({b,d,f}) = 21 < u({b,d}) ⇒ không cắt tỉa kiểu Apriori bằng u(X), phải dùng cận trên (TWU, lu, su).

Mô hình hóa Utility trong IPS

GIAO DỊCH T
một fingerprint
= một lần quét Wi-Fi

→

ITEM i
một WAP được phát hiện (RSSI ≠ 100)

→

UTILITY
u(i,T) = q(i,T) × p(i)
RSSI chuẩn hoá × giá trị của AP

→

HUI
nhóm WAP có tổng utility ≥ minUtil

BA MÔ HÌNH UTILITY — DÙNG CHUNG q(i,T), CHỈ KHÁC p(i)

MODEL A
TÍN HIỆU (SIGNAL)

p(i) = 1: utility chỉ do cường độ RSSI và đồng xuất hiện

MODEL B
MUTUAL INFORMATION

p(i) ∝ I(WAP i; Y): AP cho biết nhiều về tòa nhà–tầng thì giá trị cao

MODEL C
MI × ĐỘ HIẾM

p(i) ∝ I(WAP i; Y) · log(N / (1 + support)): phạt AP có mặt ở khắp nơi

MỤC TIÊU: kiểm tra nhóm AP có tổng utility cao có phải tập đặc trưng tốt cho định vị không — đo độ chính xác tòa nhà/tầng, sai số mét, thời gian, bộ nhớ, và so có đối chứng ở cùng số WAP.

Ba cách định nghĩa p(i)

A

Model A

Signal

$$p(i) = 1$$

Chỉ nhìn cường độ sóng và mức đồng xuất hiện: u(X) lớn khi các AP mạnh và hay xuất hiện cùng nhau.

Tổng utility CSDL: 9.058.242

Đối chứng

Nguồn: điều kiện đối chứng do bài tìm hiểu đặt ra (utility chỉ còn q)

B

Model B

Discriminative

$$p(i) = \frac{\max\left(I(A_i;\, Y),\ 10^{-6}\right)}{\max_j\ I(A_j;\, Y)}$$

WAP nào giúp biết đang ở tòa nhà–tầng nào (Y) thì có giá trị cao.

Tổng utility CSDL: 4.354.299 · p trung bình 0,175

Model chính

Nguồn: I(·;·) — Shannon, Bell Syst. Tech. J. 1948 [6]; chọn AP theo thông tin tương hỗ — Chen, Yang, Yin & Chai, IEEE TKDE 2006 [7]; chuẩn hoá về (0, 1] — bài tìm hiểu

C

Model C

Rare-discriminative

$$p(i) \ \propto\ I(A_i;\, Y) \cdot \log \frac{N}{1 + \text{support}_i}$$

Như B, nhưng phạt WAP có mặt ở khắp nơi (thừa số kiểu IDF).

Tổng utility CSDL: 6.211.852

Biến thể thứ ba

Nguồn: log(N / số lần xuất hiện) là IDF — Spärck Jones, J. Documentation 1972 [8]; ghép với MI — bài tìm hiểu

Tổng quan: 5 bước tiền xử lý

Từ một dòng CSV đến đầu vào của thuật toán EFIM

01

Làm sạch

100 = không phát hiện; kiểm tra RSSI nằm trong [−104, 0] dBm

02

Chuẩn hoá RSSI

q(i,T) ∈ [1, 100], RSSI min/max học trên trainingData

03

Tạo transaction

item = WAP; ô ≠ 100 → WAP có mặt trong giao dịch

04

Trọng số p(i)

Model A / B / C, chỉ ước lượng trên trainingData

05

Bên trong EFIM

TWU, sắp thứ tự, cắt tỉa TWU, gộp giao dịch

- **Đầu vào:** trainingData.csv (19.937 dòng) và validationData.csv (1.111 dòng), mỗi file 520 cột WAP.
- **Đầu ra:** danh sách transaction {WAP: q} và vector p(i) cho từng WAP.
- **Không làm đầy (impute) giá trị nào:** 100 = không phát hiện = item vắng mặt; 96,54% số ô WAP bằng 100, và 0 ô nằm trong 1…99.
- **Chống rò rỉ:** mọi tham số học từ dữ liệu (RSSI min/max, p(i)) chỉ lấy từ trainingData; hàm ước lượng p(i) báo lỗi nếu nhận dữ liệu khác.

Bước 1: chuẩn hoá RSSI sang “positive representation”

- Không phát hiện (100) → 0 (“không có thông tin”), tức WAP vắng mặt khỏi giao dịch.
- Đã phát hiện: đưa RSSI về [0, 1] theo min/max của trainingData, rồi ánh xạ sang [1, 100].
- Làm tròn thành số nguyên dương; không ô đã phát hiện nào bị làm tròn về 0.
- q(i,T) là số nguyên dương → EFIM cần utility dương cho các cận trên.
- Q_MAX = 100 chọn để dễ đọc, không phải siêu tham số được tinh chỉnh.

Công thức (utility nội)

$$q(i,T) = \mathrm{round}\left(1 + \frac{\mathrm{RSSI}_i - \mathrm{RSSI}_{\min}}{\mathrm{RSSI}_{\max} - \mathrm{RSSI}_{\min}} \times 99\right)$$

Nguồn: biểu diễn “positive” — Torres-Sospedra et al., ESWA 2015 [9]; thang 1…100 và làm tròn — bài tìm hiểu

WAP	RSSI thô (dBm)	q(i,T)
WAP255	−77	27
WAP284	−89	15
WAP310	−78	26
WAP366	−78	26

Dòng 3.250 của trainingData.csv (chỉ số pandas 3.248). RSSI_min = −104, RSSI_max = 0 ước lượng trên 19.937 dòng trainingData.

Bước 2: mỗi fingerprint thành một utility transaction

Dòng CSV 3.250

520 cột WAP
4 cột ≠ 100, 516 cột = 100

→

Transaction

{WAP255: 27, WAP284: 15, WAP310: 26, WAP366: 26}

→

Sau khi có p(i)

Model A: TU = 94
Model B: TU ≈ 15,5
Model C: TU ≈ 37,1

Thống kê (trainingData)	Giá trị
Số dòng (fingerprint)	19.937
Transaction không rỗng	19.861
Transaction rỗng (không phát hiện AP nào)	76
Độ dài trung bình (không rỗng)	18,06
Số item thực sự xuất hiện	465 / 520

- 76 dòng rỗng tập trung ở vài thiết bị (PHONEID 1: 59, PHONEID 22: 14, PHONEID 13: 2, PHONEID 6: 1) — nghi lỗi thu thập; vẫn giữ cho bộ phân lớp để mọi điều kiện thấy cùng dữ liệu.
- Không WAP nào xuất hiện trong hơn 23,8% fingerprint (WAP496 là WAP xuất hiện nhiều nhất).
- TU(T) = Σ q(i,T)·p(i): cùng một giao dịch có utility rất khác nhau giữa ba mô hình — chỉ vì p(i).

Bước 3: external utility p(i) — 3 mô hình

Mô hình	p(i)	Tổng utility CSDL	Vai trò
A – Signal	p(i) = 1 với mọi WAP	9.058.242	Đối chứng
B – Discriminative	max(I(A_i;Y), 10^{-6}) / max_j I(A_j;Y)	4.354.299	Mô hình chính
C – Rare-discriminative	∝ I(A_i;Y) × log(N / (1 + support_i))	6.211.852	Phạt WAP có mặt khắp nơi

Entropy và thông tin tương hỗ

$$H(Y) = -\sum_{y} P(y) \log_2 P(y)$$

$$I(A_i; Y) = \sum_{a} \sum_{y} P(a, y) \log_2 \frac{P(a, y)}{P(a)\,P(y)}$$

Nguồn: Shannon, Bell Syst. Tech. J. 1948 [6]; ước lượng từ histogram đồng thời (6 trạng thái tín hiệu × 13 lớp) — bài tìm hiểu

- Y = BUILDINGID_FLOOR (13 lớp), H(Y) = 3,639 bit.
- 6 trạng thái: "không phát hiện" + 5 khoảng dBm, biên [−104, −90, −80, −70, −60, 0].
- WAP thông tin nhất: WAP087 với 0,438 bit = 12,0% của H(Y).
- Sàn 10^{-6} giữ p > 0 vì EFIM cần utility dương; p trung bình (B) = 0,175.

Hệ quả 1: tổng utility chênh 2,08 lần dù cùng dữ liệu và cùng q ⇒ minUtil phải biểu diễn theo % tổng utility.

Hệ quả 2 (hạn chế lớn nhất): trên 465 WAP, hạng theo MI và hạng theo số lần phát hiện tương quan Spearman ρ = 0,9908 [10] ⇒ Model B gần như là tần suất phát hiện được tham số hoá lại.

Từ fingerprint Wi-Fi đến bài toán HUIM

Fingerprint không có sẵn q và p, nên phải tự định nghĩa — đây là lựa chọn thiết kế của bài tìm hiểu

Khái niệm HUIM	Item	Transaction	q(i,T)	p(i)	HUI
Trong IPS	Một WAP	Một lần đo (fingerprint)	RSSI chuẩn hoá 1…100	**Model A, B hoặc C**	Nhóm WAP utility cao

Chỉ thay p(i), giữ nguyên mọi thứ khác: cùng dữ liệu, cùng q, cùng EFIM, cùng bộ định vị.

TỪ HUI ĐẾN TẬP WAP — 2 QUY TẮC

- **Union:** lấy mọi WAP xuất hiện trong ít nhất một HUI — minUtil là tham số duy nhất.
- **Top-n:** lấy n WAP có điểm đóng góp cao nhất (công thức bên phải).
- Cả hai quy tắc cố định TRƯỚC khi có bất kỳ kết quả độ chính xác nào.
- Lần khai phá bị dừng giữa chừng có tập HUI lệch theo thứ tự DFS → không dùng để xếp hạng WAP.

Điểm đóng góp của WAP i

$$\text{contrib}(i) = \sum_{X \in \text{HUIs},\ i \in X} \frac{u(X)}{|X|}$$

Mỗi HUI chia đều utility cho các WAP thành viên; WAP có tổng đóng góp cao xếp trước.

Nguồn: quy tắc xếp hạng do bài tìm hiểu đặt ra (không lấy từ tài liệu)

Thuật toán EFIM

Zida, Fournier-Viger, Lin, Wu & Tseng — Knowledge and Information Systems, 2017 [5]

01

Tiền xử lý

Tính TU, TWU; bỏ mục TWU < minUtil; sắp mục theo TWU **tăng** dần



02

Chiếu CSDL

Xuống nút α ∪ {z}: mỗi giao dịch chỉ giữ phần đứng sau z



03

Duyệt sâu (DFS)

Cây liệt kê tập mục; chỉ mở nhánh có su ≥ minUtil



04

Tính utility

Tính u(X) chính xác cho từng tập được duyệt

$$u(X) = \sum_{T \supseteq X} u(X, T)$$

05

Xuất kết quả

Giữ các tập có u(X) **≥** minUtil

HUIs

TỐI ƯU EFIM

HAI CẬN TRÊN lu VÀ su

local utility và subtree utility loại sớm mục / nhánh không thể đạt minUtil (slide sau)

CHIẾU & GỘP GIAO DỊCH

giao dịch chiếu giống hệt nhau được gộp; Fast Utility Counting tính lu, su trong một lượt quét

EFIM: hai cận trên lu và su

Công thức

$$\mathrm{re}(\alpha, T) = \sum_{i \in T,\ i \succ \alpha} u(i, T)$$

$$\mathrm{lu}(\alpha, z) = \sum_{T \supseteq \alpha \cup \{z\}} [u(\alpha, T) + \mathrm{re}(\alpha, T)]$$

$$\mathrm{su}(\alpha, z) = \sum_{T \supseteq \alpha \cup \{z\}} \left[u(\alpha, T) + u(z, T) + \sum_{i \in T,\ i \succ z} u(i, T) \right]$$

- Chỉ giữ z có lu(α, z) ≥ minUtil (tập Secondary); z khác bị loại khỏi CẢ cây con của α.
- Chỉ mở nhánh α ∪ {z} khi su(α, z) ≥ minUtil (tập Primary).
- Tại gốc: lu(∅, z) = TWU(z) ⇒ cắt tỉa TWU là trường hợp riêng.
- re(α, T): utility còn lại của các mục đứng sau α trong T.

Nguồn: Zida, Fournier-Viger, Lin, Wu & Tseng, KAIS 2017 [5] — cả hai cận trên và Fast Utility Counting

Ví dụ chạy chuẩn trong [5] — 5 giao dịch, minUtil = 30

Mục	TWU	Thứ tự	su gốc	Vai trò
f	30	1	30	Primary
g	38	2	38	Primary
d	58	3	53	Primary
b	61	4	36	Primary
a	65	5	37	Primary
e	88	6	27	Chỉ Secondary
c	96	7	13	Chỉ Secondary

- EFIM trả về 7 HUI nhưng chỉ duyệt 18 / 127 tập mục khả dĩ; 19 nhánh bị loại nhờ su.
- Lý do chọn EFIM: đánh giá thực nghiệm độc lập [11]; SPMF [12] cần Java nên EFIM được cài lại bằng Python và đối chiếu oracle vét cạn.

Tiền xử lý bên trong EFIM

Chạy ở đầu mỗi lần khai phá, trước khi tìm kiếm theo chiều sâu

1. Kiểm tra mọi p(i) > 0 và q > 0; thiếu thì báo lỗi.
2. Tính TU(T) = Σ q·p cho mỗi giao dịch; TWU(i) = tổng TU của các giao dịch chứa i.
3. Cắt tỉa TWU: bỏ item có TWU < minUtil.
4. Sắp item theo TWU tăng dần (bằng nhau thì theo nhãn).
5. Dựng CSDL đã cắt tỉa: bỏ giao dịch rỗng, gộp giao dịch giống hệt nhau (có cộng dồn số lần xuất hiện để độ hỗ trợ vẫn đúng).
6. Tính local utility / subtree utility cho gốc bằng Fast Utility Counting.

minUtil	A: item còn lại	B: item còn lại	C: item còn lại
20%	17	41	31
10%	56	60	60
5%	151	93	117
2,5%	231	175	218
2%	250	204	227

minUtil tính theo % tổng utility của CSDL. Ngưỡng càng cao thì cắt tỉa TWU càng loại nhiều item: trong 465 item ban đầu, ở minUtil 20% chỉ còn 17 (A), 41 (B) và 31 (C).

Thực nghiệm trên bộ dữ liệu UJIIndoorLoc

19.937
fingerprint huấn luyện

1.111
fingerprint kiểm định

520
cột WAP (đặc trưng Wi-Fi)

QUY TRÌNH THỰC NGHIỆM

01
TIỀN XỬ LÝ RSSI
100 → không phát hiện; RSSI → 1...100 (học trên train)

→

02
CHUYỂN ĐỔI FINGERPRINT
thành 19.861 utility transaction

→

03
KHAI PHÁ HUIM VỚI EFIM
37 lần chạy, 3 mô hình p(i), minUtil 20% → 1,5%

→

04
ĐỊNH VỊ k-NN
V1: k = 1, Manhattan; V2: Bray-Curtis, k = 12

→

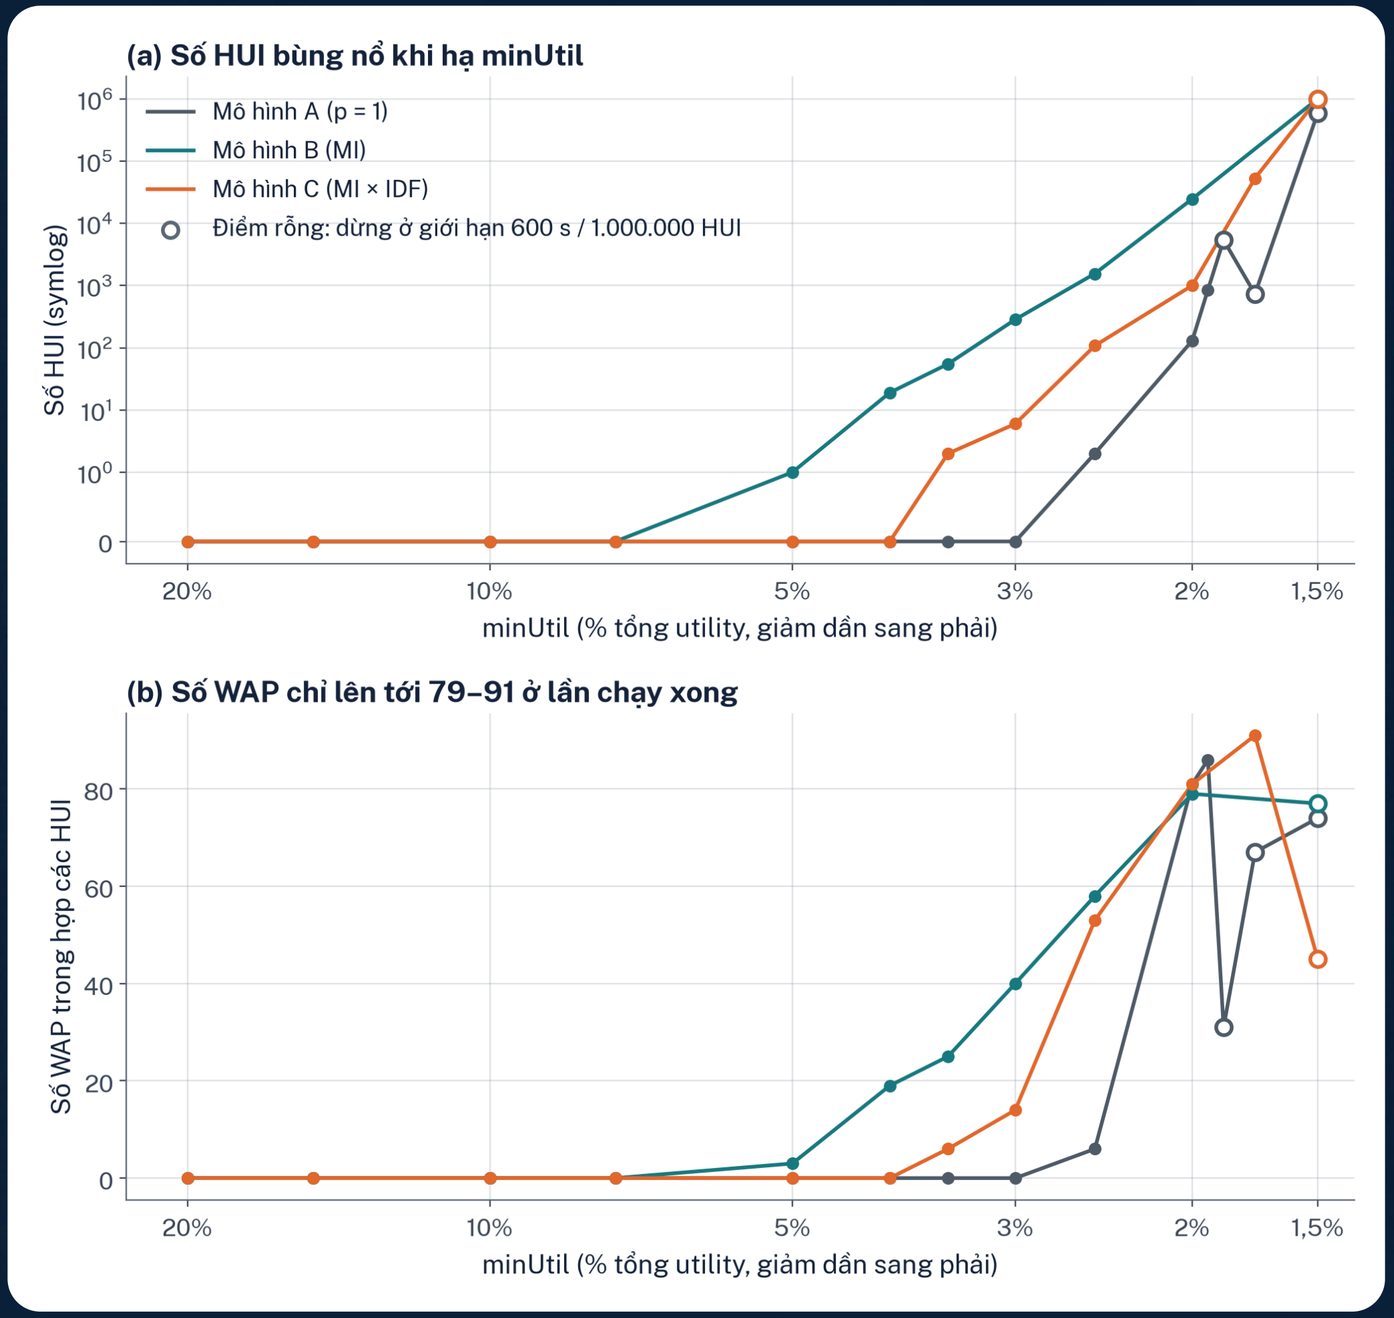
05
ĐÁNH GIÁ HIỆU NĂNG
tòa nhà, tầng, sai số mét, thời gian, bộ nhớ

KẾT QUẢ

Mọi tham số chọn trên trainingData; validationData chỉ dùng để đánh giá, một lần cho mỗi điều kiện (190 điều kiện ở Version 1, 5 bước S0–S4 ở Version 2).

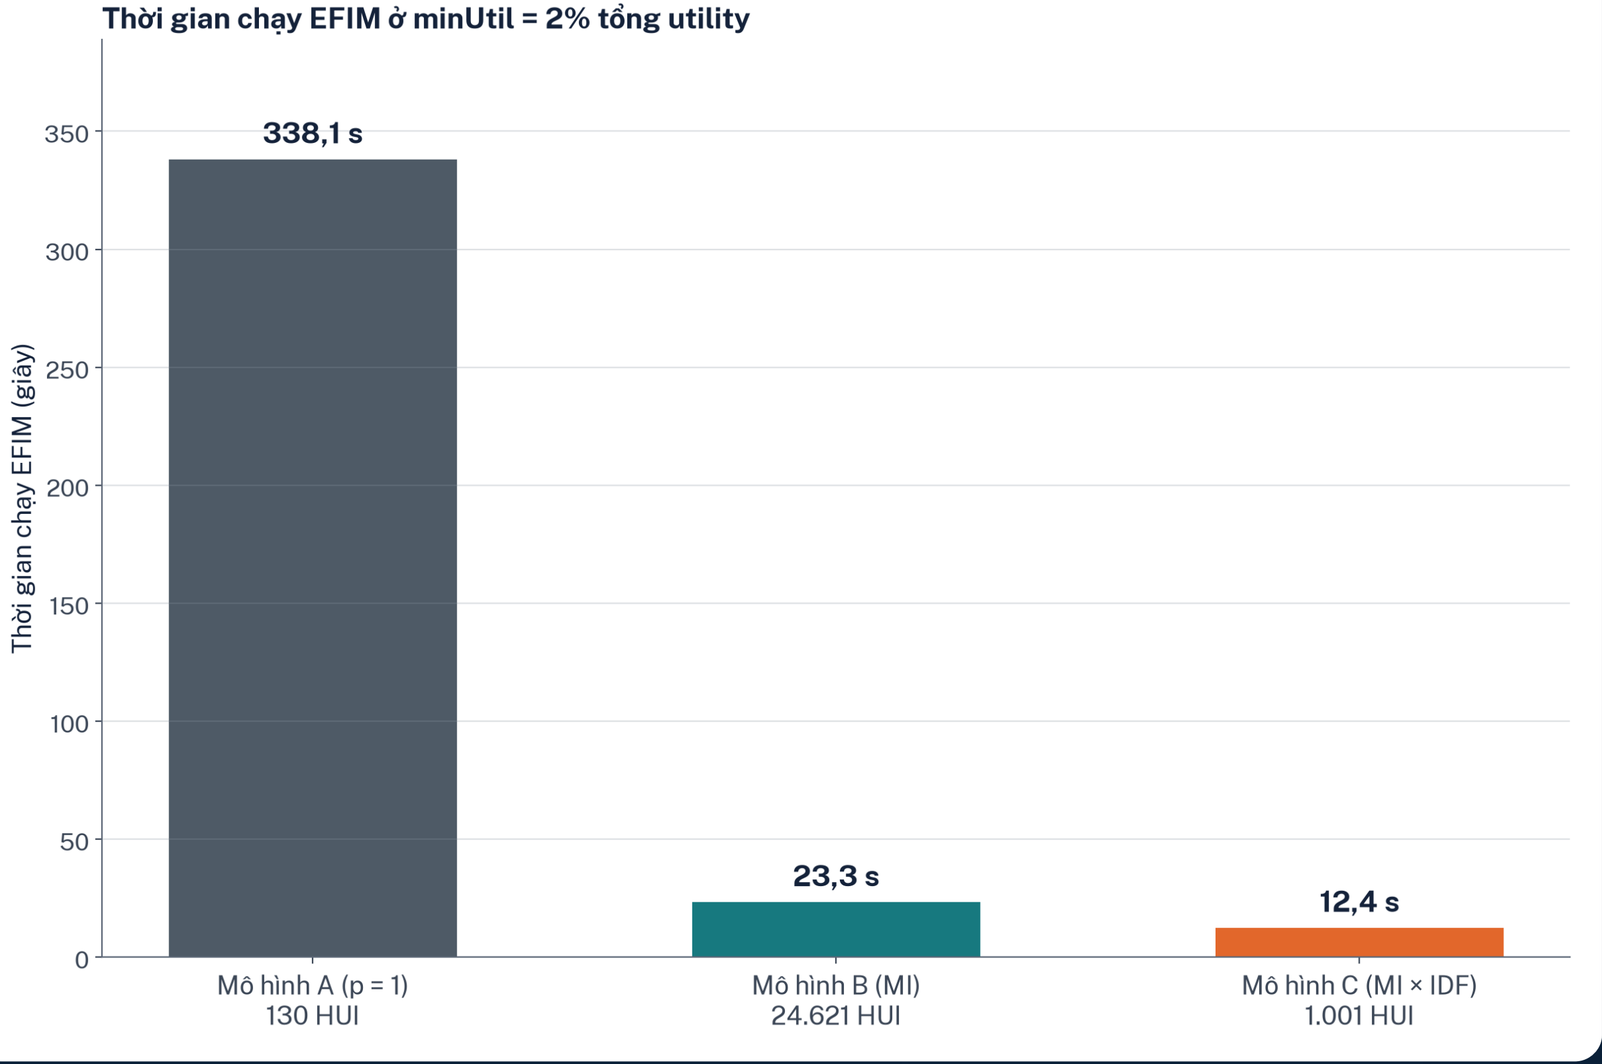
Trong HUIM, mỗi phần tử có một giá trị utility và thuật toán tìm những tập phần tử có tổng utility đạt ngưỡng **minUtil**.

- Model A (p = 1): 8 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 2,5%
- Model B (MI): 4 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 5%
- Model C (MI × IDF): 6 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 3,5%
- Chuyển pha rất gắt: từ “không có gì” sang “vượt ngân sách” chỉ trong một bước ngưỡng.
- Số HUI khổng lồ nhưng chỉ đến từ 79–91 WAP riêng biệt (lần chạy xong).



p(i) quyết định chi phí khai phá

Cùng ngưỡng minUtil = 2% tổng utility, EFIM chạy trên 19.861 giao dịch



14,5–27,2×

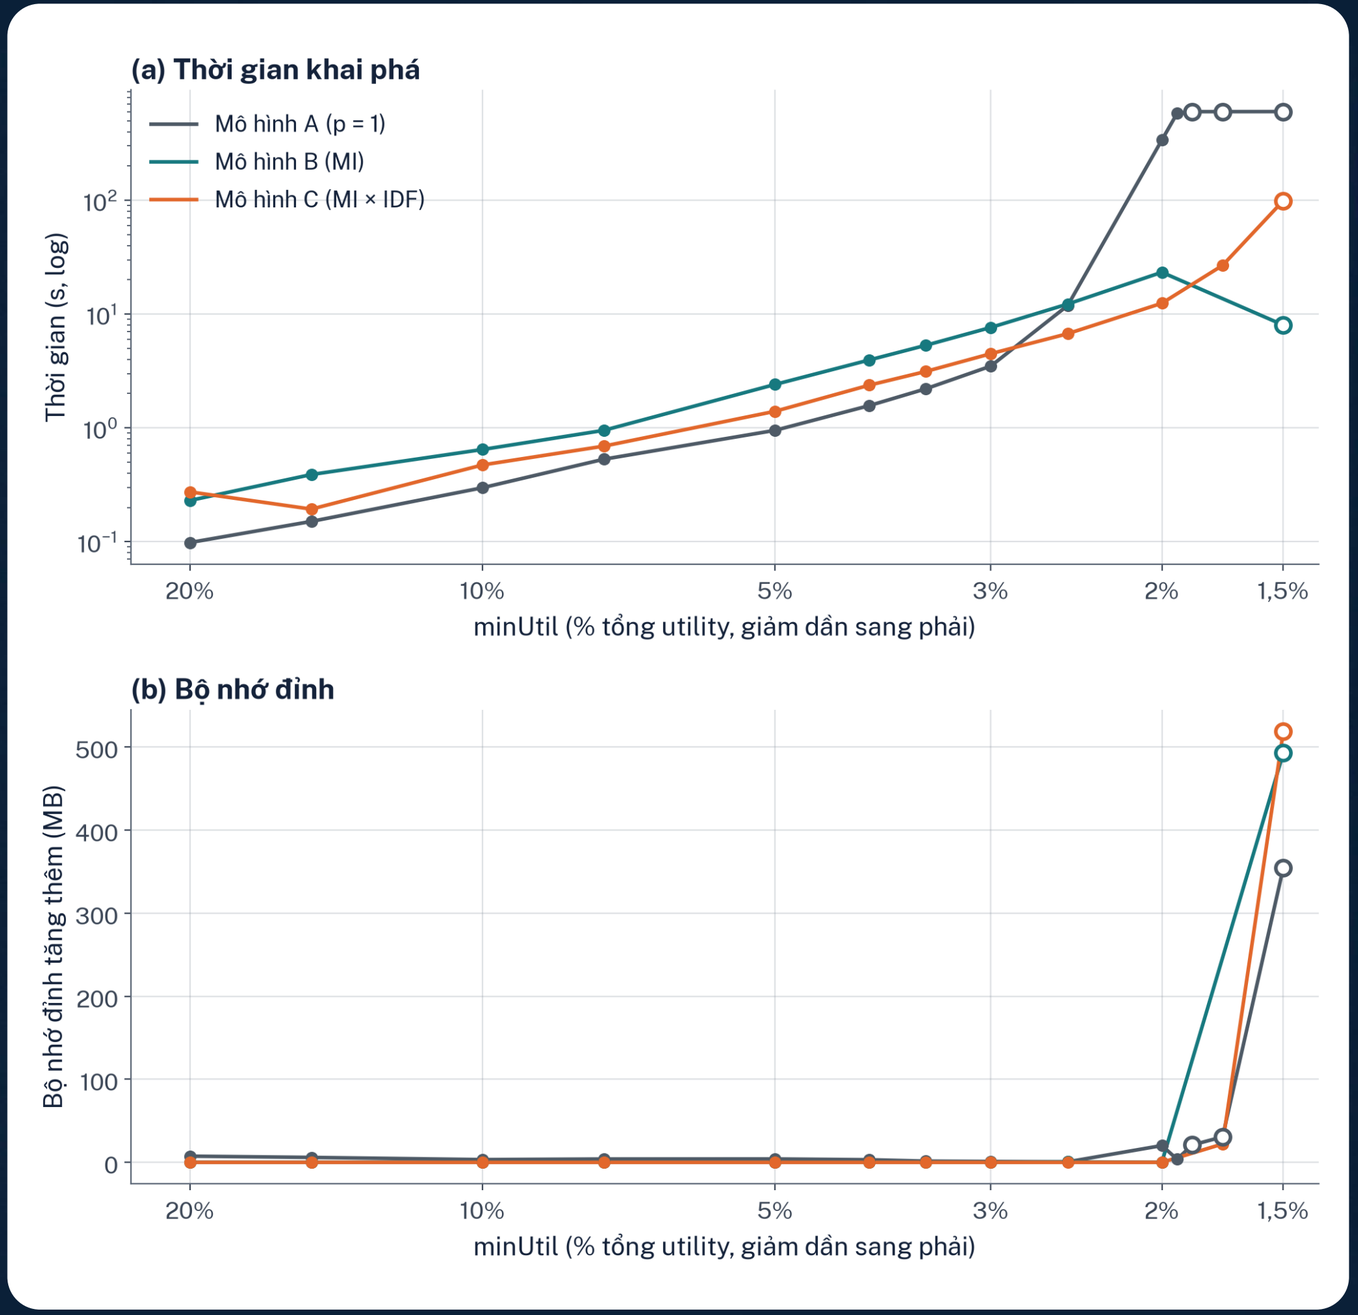
Model A chậm hơn B và C ở cùng ngưỡng.

130 vs 24.621

Số HUI của A so với B: A có ít HUI hơn nhưng vẫn chậm hơn, vì p = 1 làm các cận trên ít phân hoá mục nên cắt tỉa kém.

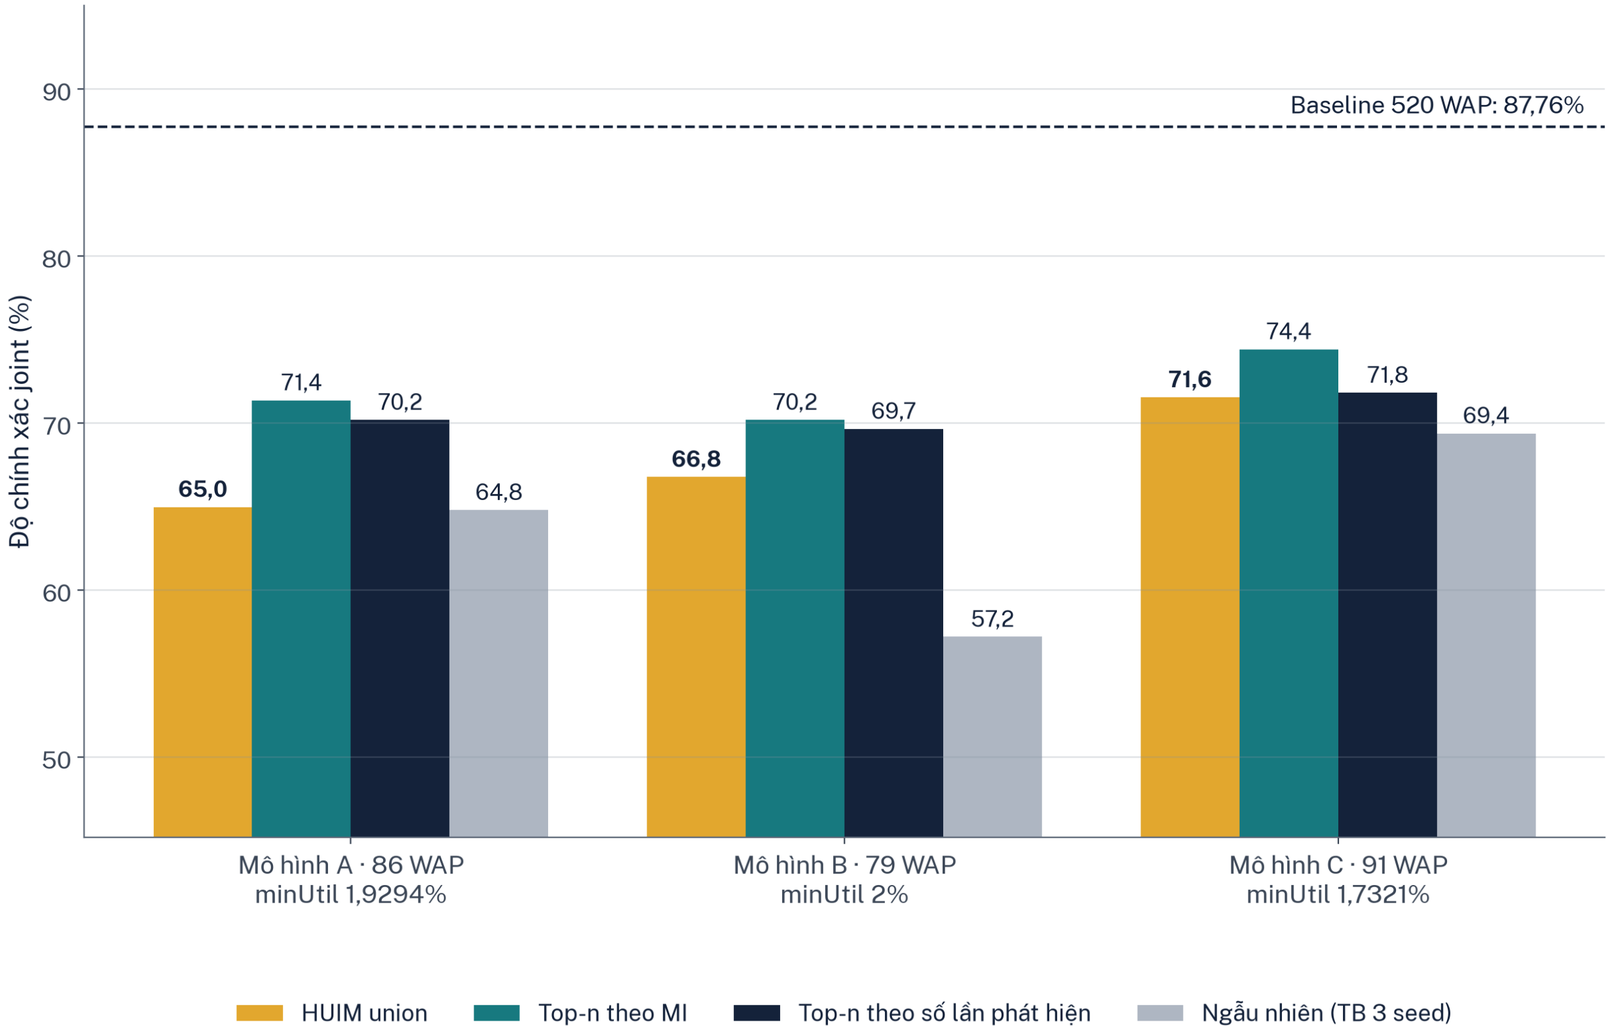
Runtime và bộ nhớ theo ngưỡng

- Model A (p = 1): 0,10–600,89 s; bộ nhớ đỉnh 0,6–354,7 MB; 3 lần dừng (ABORTED)
- Model B (MI): 0,23–23,29 s; bộ nhớ đỉnh 0,0–492,8 MB; 1 lần dừng (ABORTED)
- Model C (MI × IDF): 0,19–99,17 s; bộ nhớ đỉnh 0,0–518,9 MB; 1 lần dừng (ABORTED)
- Spearman ρ(số nút đã duyệt, runtime) = 0,995, 0,973, 0,998 [10] → chi phí là chi phí TRÊN MỖI NÚT.
- Giới hạn mỗi lần chạy: 600 s hoặc 1.000.000 HUI; vượt thì dừng có kiểm soát và giữ kết quả một phần.



HUIM có hơn các đối chứng không?

Độ chính xác joint (tòa nhà + tầng) trên validationData, cùng số WAP; baseline 520 WAP = 87,76% (k-NN Version 1)



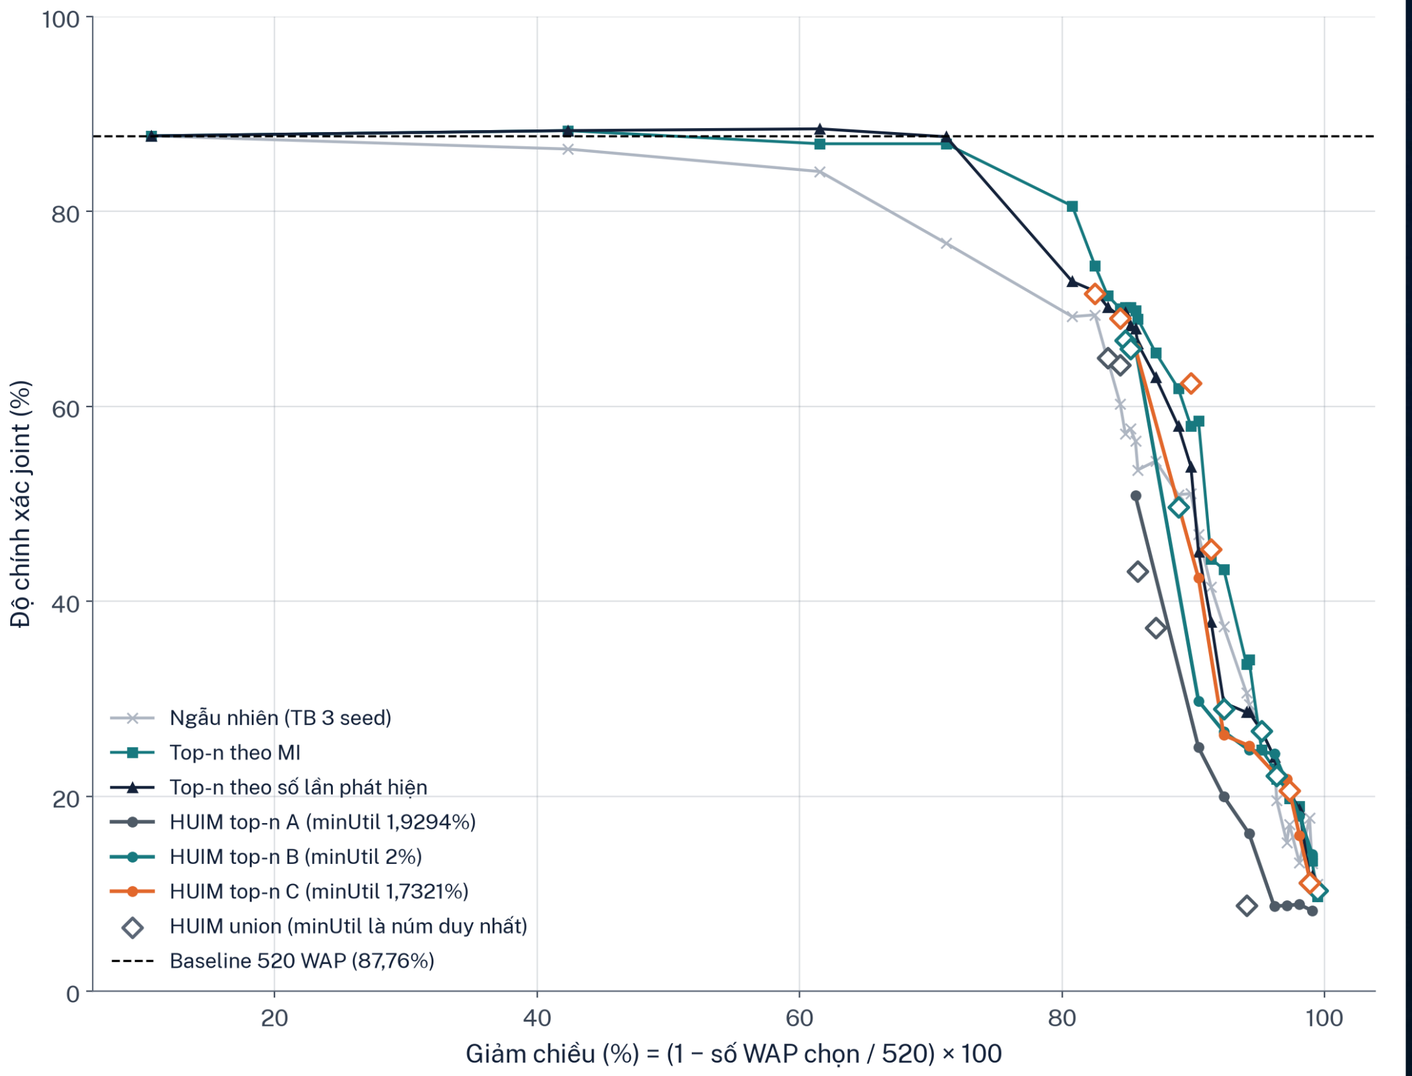
5/8 ngân sách WAP: HUIM tốt nhất vượt chọn ngẫu nhiên

3/8 vượt top-n theo mutual information

3/8 vượt top-n theo số lần phát hiện

Kết luận trung thực: HUIM union thắng ngẫu nhiên ở B và C nhưng thua top-n theo MI ở cả ba mô hình. Mọi cách chọn đều thấp hơn dùng đủ 520 WAP.

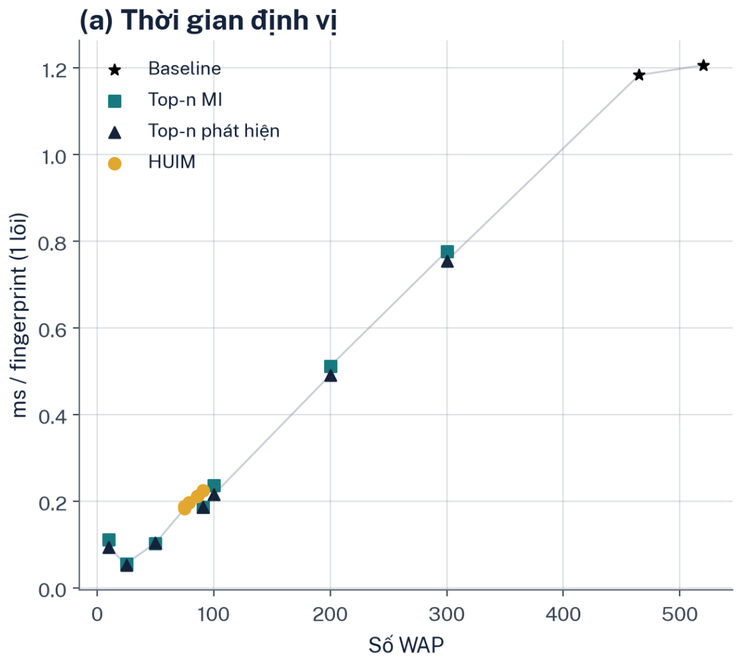
Feature Reduction và Accuracy

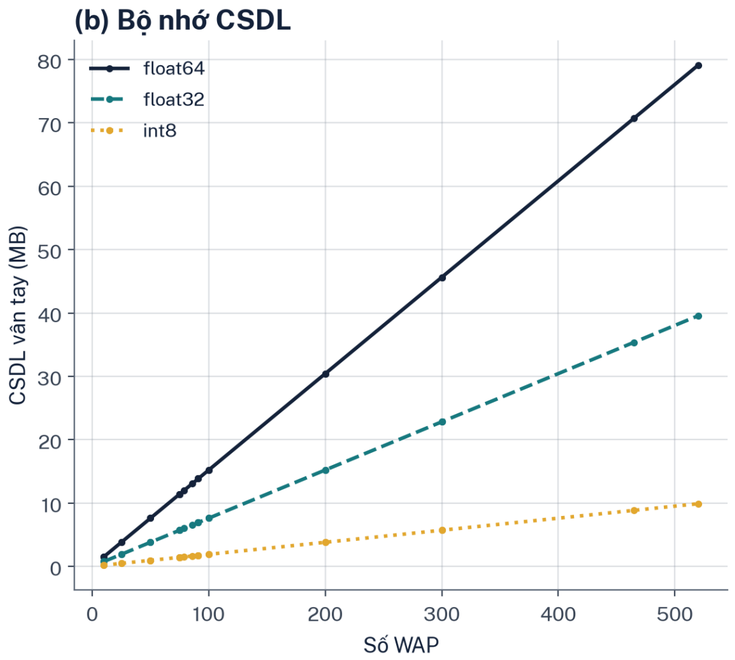


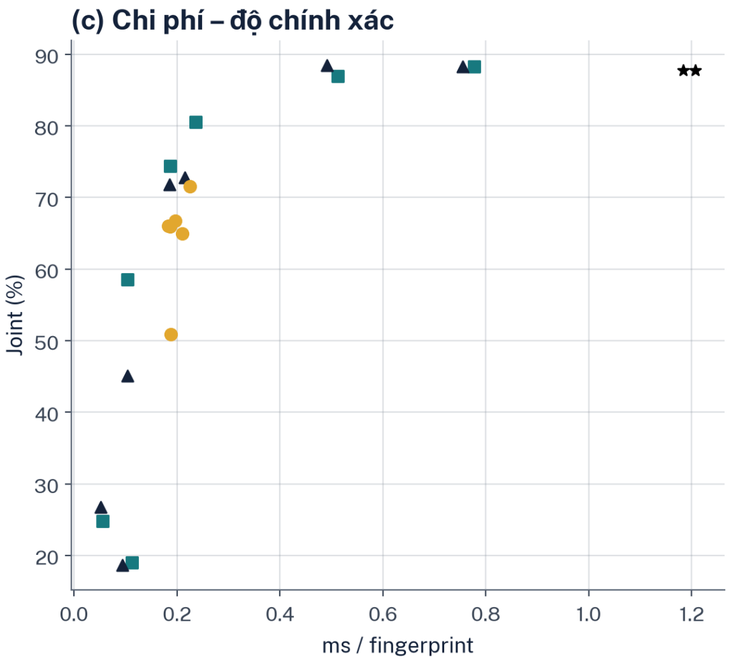
- KHÔNG tập con nào do HUIM chọn đạt joint accuracy của baseline toàn bộ WAP.
- Building accuracy chịu được giảm chiều mạnh; Floor accuracy là ràng buộc chặt.
- Tập HUIM lớn nhất có 91 WAP; ở ngân sách đó tốt nhất mọi phương pháp chỉ 74,44% (control_top_mi__n91).
- Cần 200 WAP (control_top_support__n200, 88,48%) mới chạm baseline — vượt xa trần mà HUIM cung cấp.
- Hình thoi = điểm union, nơi minUtil là núm điều khiển duy nhất.

Kết quả và Phân tích

Đánh giá thời gian và bộ nhớ







Nhận xét

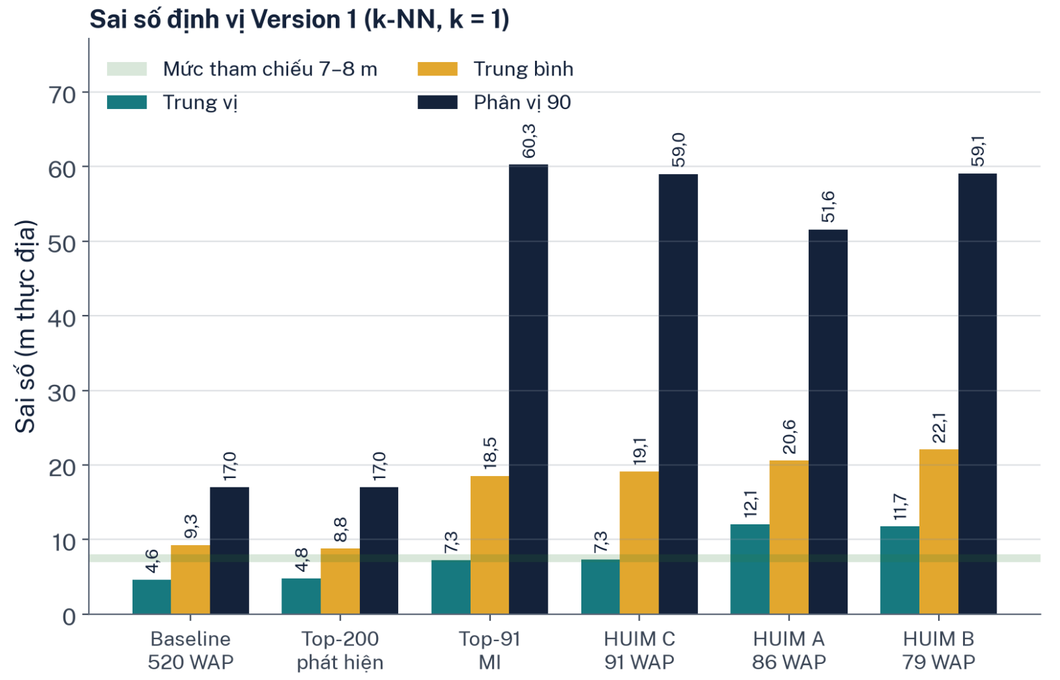
- Baseline 520 WAP: 1,207 ms/fingerprint, CSDL vân tay 79,1 MB (float64).
- control_top_support__n200 (200 WAP): 2,5× nhanh hơn, 38% bộ nhớ, joint 88,48%.
- HUIM tốt nhất (91 WAP): 5,4× nhanh hơn, 18% bộ nhớ, nhưng joint chỉ 71,56%.
- Đo một lõi, lặp lại lấy trung vị; bộ nhớ CSDL = dòng × cột × kích thước phần tử. Bộ định vị Version 2 chưa được đo thời gian riêng.

Kết quả và Phân tích

Độ chính xác định vị theo mét — V1

Nhận xét

- Baseline V1: trung vị 6,02 m toạ độ chiếu = 4,61 m thực địa; trung bình 12,11 m chiếu = 9,28 m thực địa.
- Trung vị DƯỚI dải 7–8 m; trung bình TRÊN dải vì phân bố có đuôi dài (P95 = 27,8 m).
- Toạ độ là EPSG:3857 Web Mercator — xác định bằng nghịch đảo phép chiếu, rơi cách campus UJI 139,7 m.
- Web Mercator KHÔNG bảo toàn khoảng cách: hệ số 1,305268 → đọc thẳng từ cột toạ độ lớn hơn thực tế khoảng 31%.



Sai số thực địa của một fingerprint

$$e = \sqrt{(x - \hat{x})^2 + (y - \hat{y})^2} \times \cos\varphi$$

φ = 39,9927° ⇒ cos φ = 0,766126

Nguồn: hệ số tỉ lệ Mercator sec φ — Snyder, USGS Prof. Paper 1395, 1987 [13]; báo cáo trung vị, trung bình, phân vị theo Adler et al., IPIN 2015 [14]

Version 2

Tối ưu sai số định vị theo mét

Giữ nguyên dữ liệu, HUIM và giao thức chống rò rỉ — chỉ thay bộ ước lượng toạ độ.

9,28 m → 5,36 m (−42%)

sai số trung bình (m thực địa) trên 1.111 fingerprint kiểm định



Vì sao Version 1 sai số lớn?

1

Chọn tham số sai mục tiêu

k = 1, Manhattan được chọn cho bài toán PHÂN LOẠI tầng, không phải ước lượng toạ độ.

2

Phép chia dev không giống tập kiểm định

Chia ngẫu nhiên 75/25 đặt fingerprint đo tại cùng điểm vào cả hai phía nên k = 1 thắng; validationData dùng thiết bị khác (9/11 mã thiết bị không có trong train), tại 1.074 vị trí.

3

Phương sai cao của k = 1

Toạ độ dự đoán chính là một vị trí huấn luyện: láng giềng sai là sai số trọn vẹn.

4

Hoà khoảng cách

RSSI là số nguyên nên khoảng cách Manhattan thường bằng nhau; với k = 1 cách phá hoà quyết định toạ độ.

5

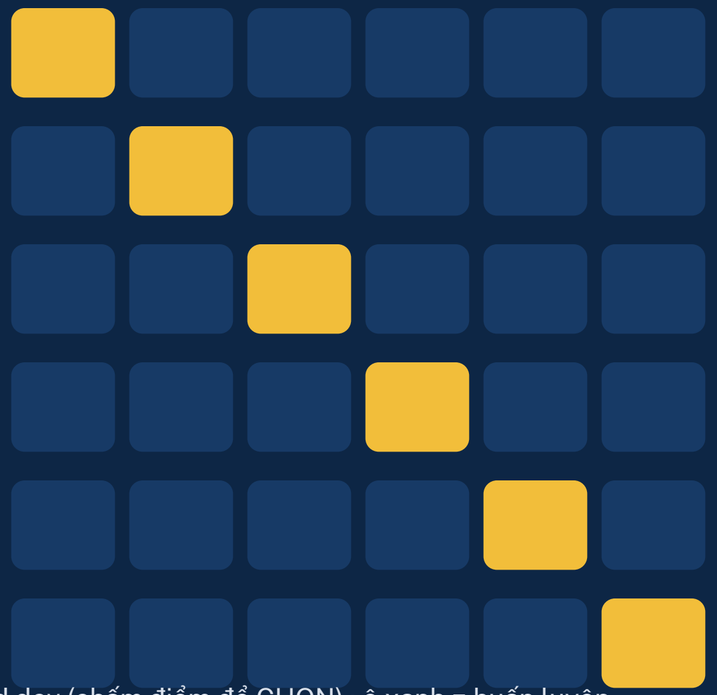
Lệch thiết bị

Điện thoại khác nhau đo RSSI lệch mức, làm sai khoảng cách tính trên RSSI thô [15], [16].

Giao thức chọn mô hình không rò rỉ

GroupKFold(6) theo USERID trên trainingData: 18 người đo chia 6 nhóm; mỗi fold dev chỉ gồm người đo mà mô hình chưa thấy

6 fold giữ lại người đo



Ô **vàng** = fold dev (chấm điểm để CHỌN) · ô xanh = huấn luyện

Bước	Dữ liệu dùng
Chuẩn hoá RSSI, p(i), khai phá HUIM, chọn WAP	trainingData
Chọn siêu tham số k-NN (Version 1)	Chia ngẫu nhiên 75/25 của train
Chọn mô hình định vị (Version 2)	6 fold giữ lại người đo
Huấn luyện bộ định vị cuối	Toàn bộ trainingData
Đánh giá	validationData, 1 lần / bước

- Tiêu chí chọn: sai số trung bình (m thực địa) trên các fold dev.
- 5 bước S0 → S4 nối tiếp; bước sau chỉ được nhận nếu giảm sai số dev ít nhất 0,05 m.
- validationData chỉ chấm điểm mỗi bước một lần, SAU khi lựa chọn đã xong.

Leave-users-out mô phỏng đúng tình huống kiểm định: người đo / thiết bị mới, chưa từng có trong dữ liệu huấn luyện.

Các cải tiến của Version 2 — công thức và nguồn

1 · Biểu diễn tín hiệu (RSSI phát hiện được)

$$\text{powed} = \left(\frac{\text{RSSI} + 105}{105}\right)^{e}$$

$$\text{exponential} = \frac{\exp\left((\text{RSSI} + 105)/24\right)}{\exp(105/24)}$$

Lưới: positive, powed, exponential; chọn exponential

Nguồn: Torres-Sospedra et al., ESWA 2015 [9]

2 · Khoảng cách Bray–Curtis

$$d_{\text{BC}}(a, b) = \frac{\sum_j |a_j - b_j|}{\sum_j (a_j + b_j)}$$

Lưới: euclidean, manhattan, braycurtis, cosine; chuẩn hoá theo tổng cường độ của hai vector

Nguồn: Bray & Curtis, Ecol. Monogr. 1957 [17]; dùng cho vân tay Wi-Fi — Torres-Sospedra et al., ESWA 2015 [9]

3 · k-NN có trọng số nghịch đảo khoảng cách

$$\hat{x} = \frac{\sum_{i=1}^{k} w_i x_i}{\sum_{i=1}^{k} w_i}, \qquad w_i = \frac{1}{d_i^{\,p}}$$

k từ 1 đến 30, p từ 0 đến 4; chọn k = 12, p = 4

Nguồn: k-NN trong không gian tín hiệu — Bahl & Padmanabhan, INFOCOM 2000 [18]; trọng số nghịch đảo khoảng cách mũ p — Shepard, ACM Nat. Conf. 1968 [19]

4 · Dò lệch thiết bị và ensemble

$$\delta^{*} = \arg\min_{\delta} \min_{j} d(r + \delta,\ f_j)$$

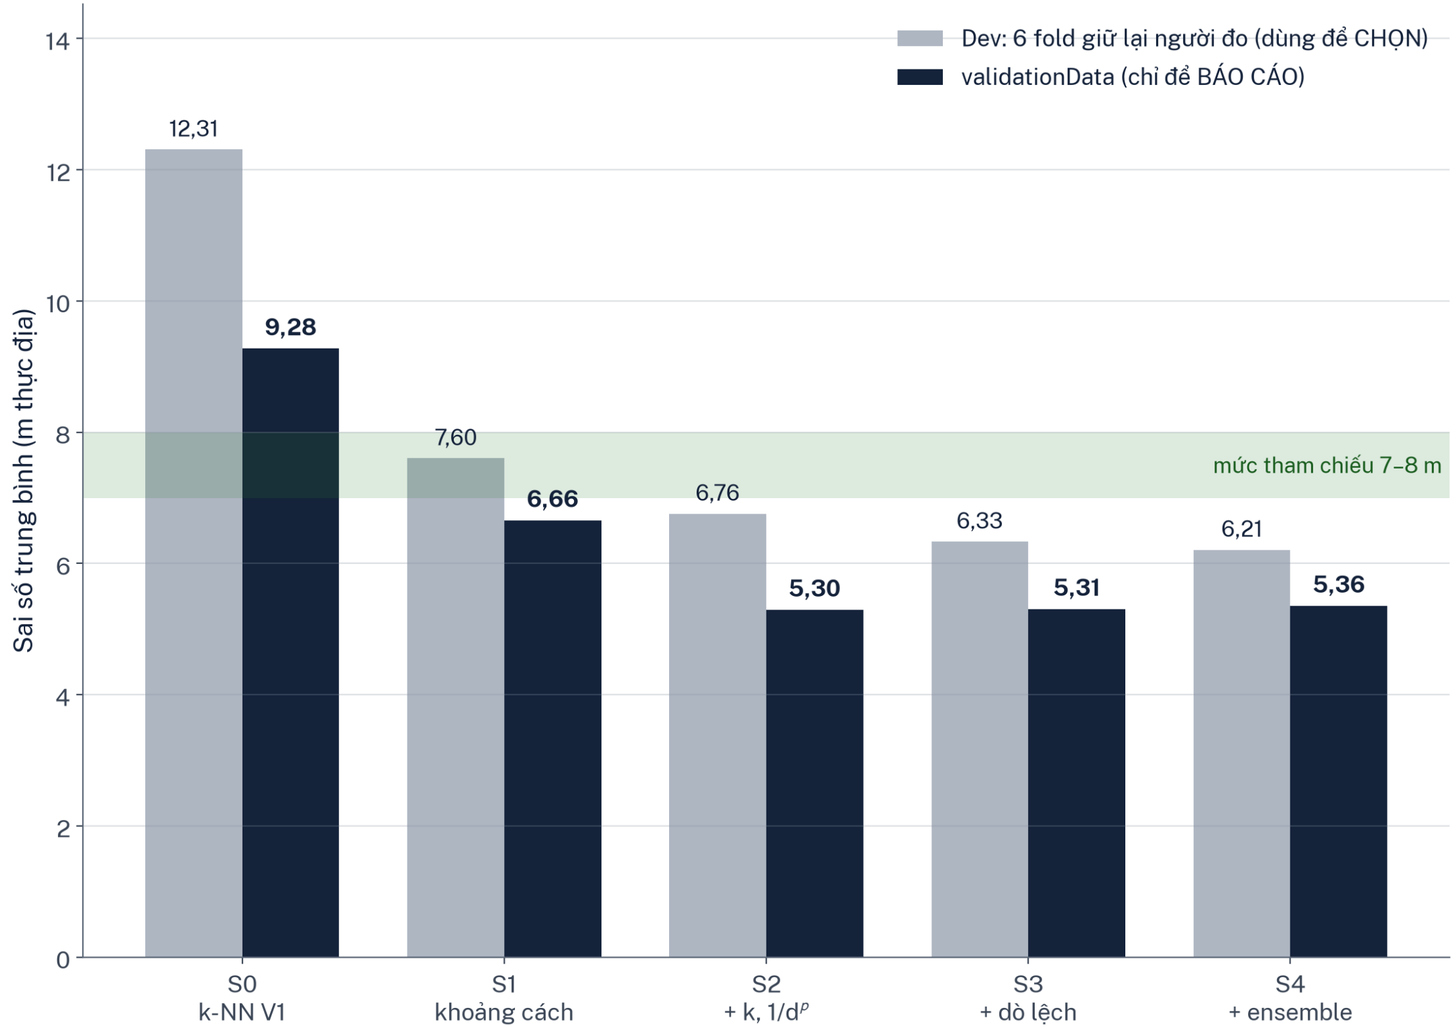
$$\hat{x} = \tfrac{1}{2}\left(\hat{x}_{\text{exp}} + \hat{x}_{\text{pos}}\right)$$

$\delta \in \{-6, \ldots, +6\}$ dB, bước 3 dB; chỉ dùng tín hiệu của chính truy vấn

Nguồn: thiết kế của bài tìm hiểu — chưa đối chiếu tài liệu về hiệu chỉnh lệch thiết bị [CẦN BỔ SUNG NGUỒN]

Phá hoà tất định: láng giềng sắp theo (khoảng cách, chỉ số dòng) — kết quả không phụ thuộc cách thư viện xử lý hoà.

Kết quả từng bước S0 → S4

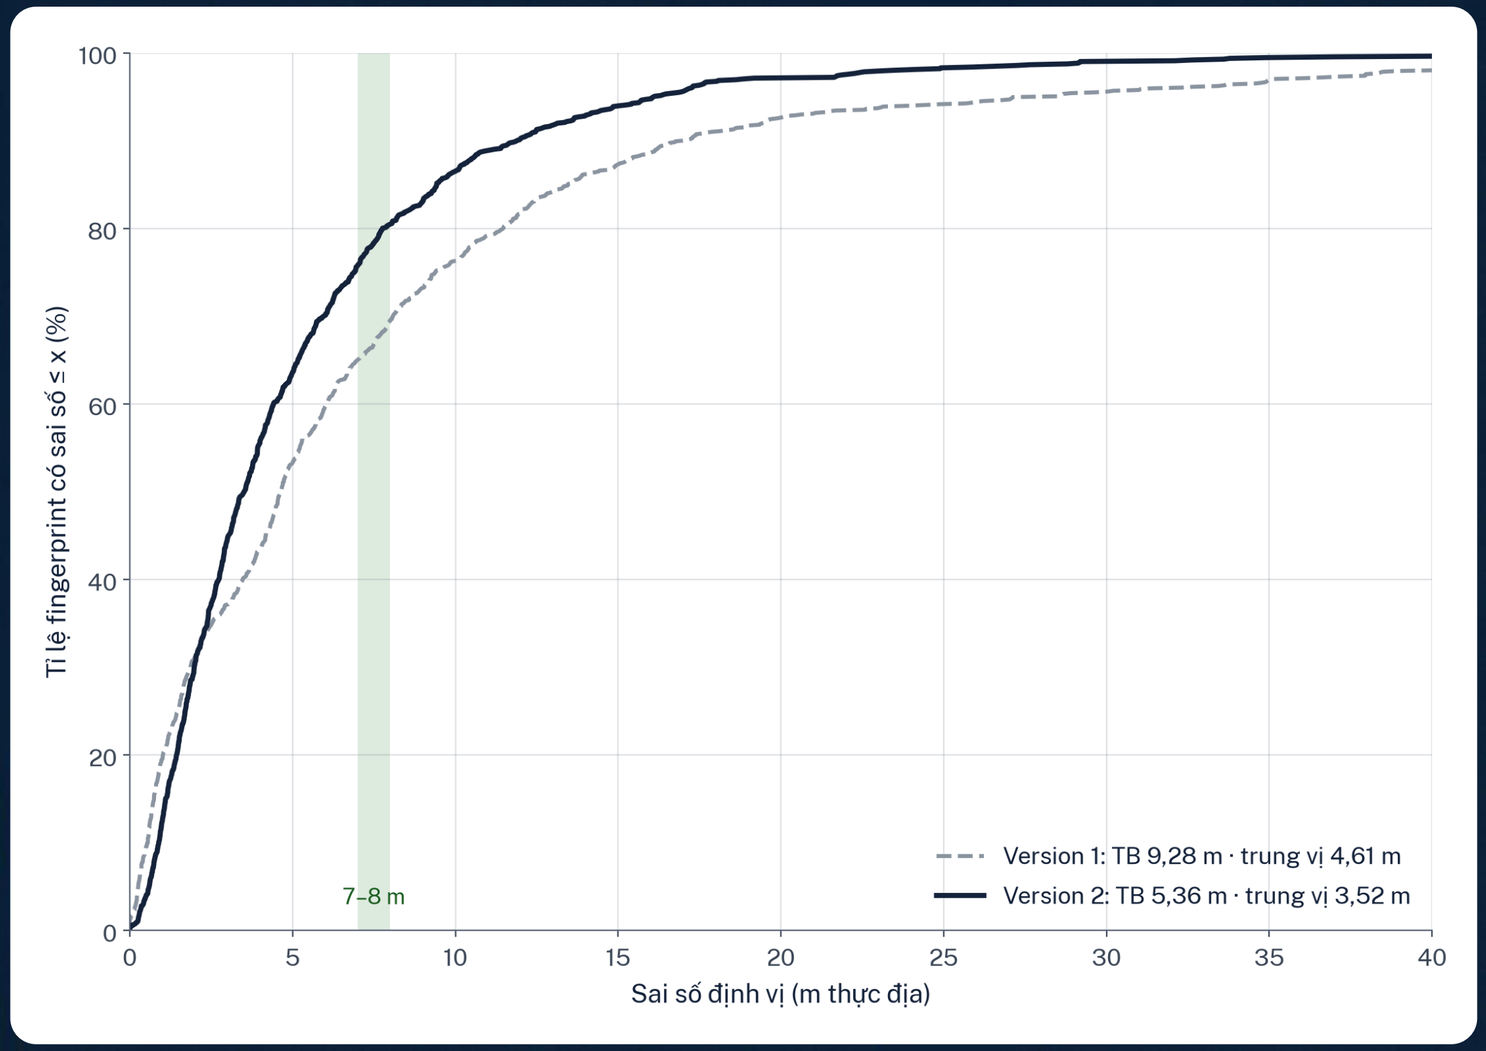


Bước	Dev TB	KĐ TB	KĐ trung vị	Joint
S0	12,31	9,28	4,61	87,76%
S1	7,60	6,66	4,61	92,17%
S2	6,76	5,30	3,39	93,70%
S3	6,33	5,31	3,49	94,69%
S4	6,21	5,36	3,52	94,69%

m thực địa · KĐ = validationData

- Phần lớn mức giảm đến từ S1–S2 (khoảng cách + k láng giềng có trọng số).
- **Trung thực:** S2 có sai số KĐ thấp nhất (5,30 m), thấp hơn S4 (5,36 m). Giao thức chọn S4 trên dev nên giữ S4; chọn lại theo số KĐ là dùng tập kiểm tra để chọn mô hình.
- Dò lệch và ensemble chủ yếu nâng độ chính xác tầng.

Phân bố sai số: Version 1 so với Version 2



Version 2 dịch cả phân bố sai số sang trái — không chỉ trung bình mà cả đuôi (P90, P95, sai số lớn nhất).

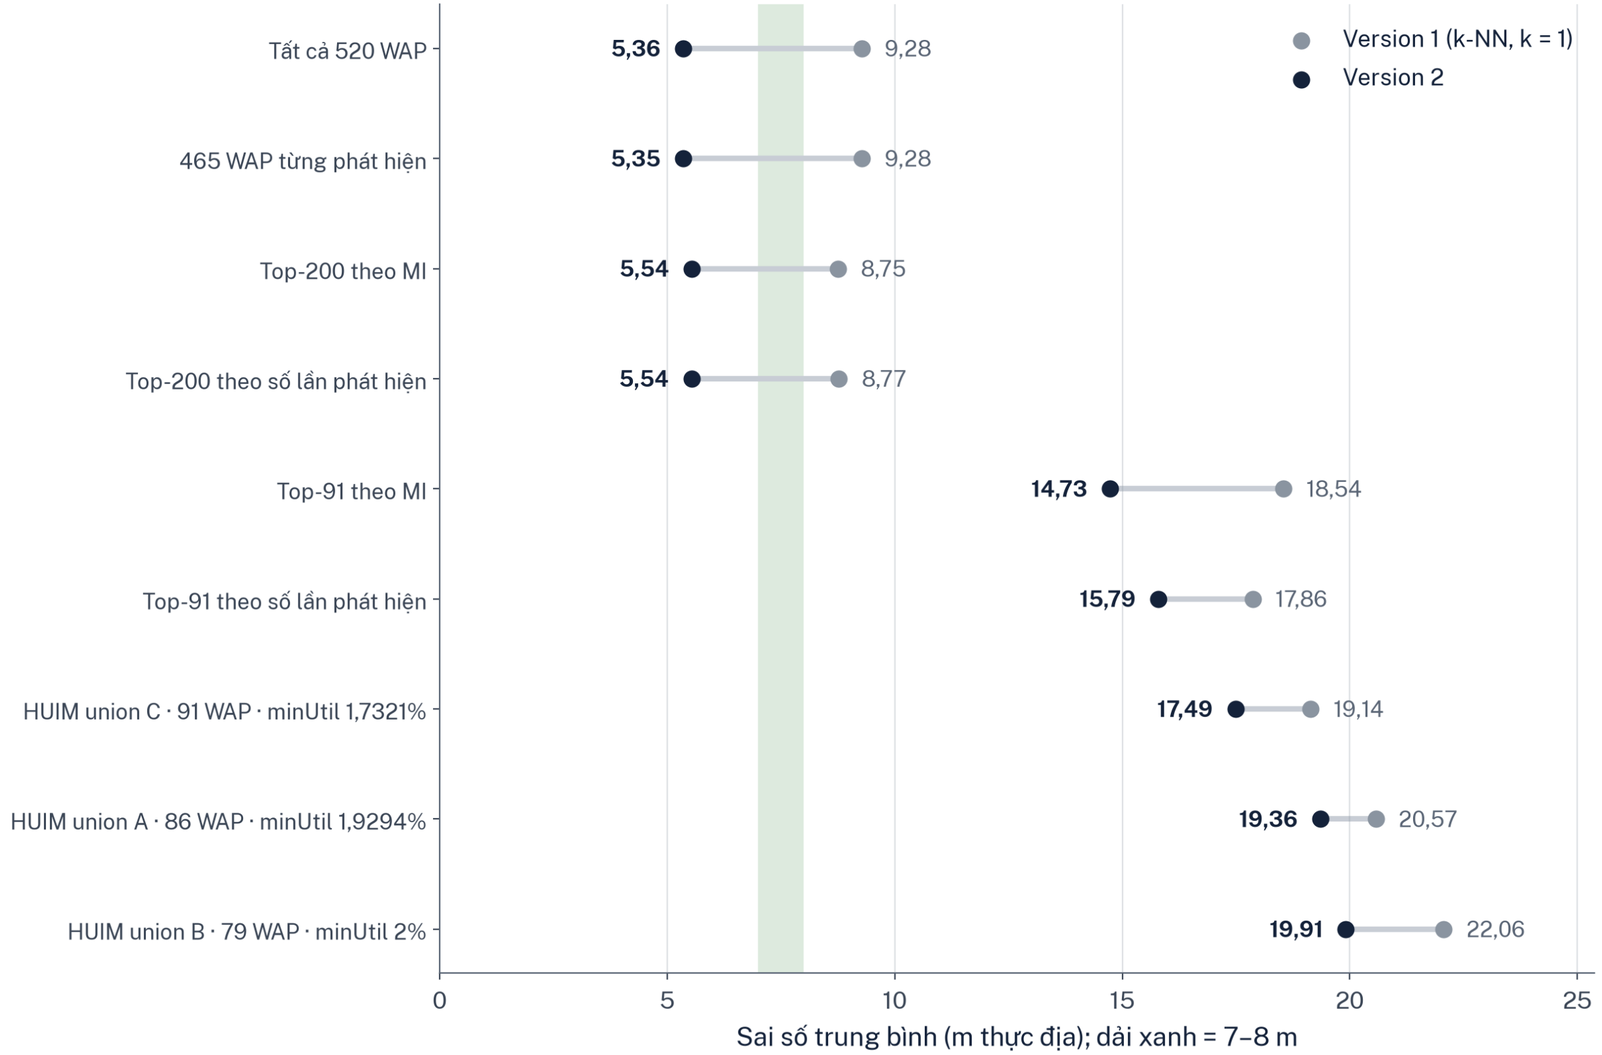
m thực địa	V1	V2
Trung bình	9,28	5,36
P25	1,48	1,70
Trung vị	4,61	3,52
P75	9,39	6,90
P90	17,02	11,89
P95	27,81	16,09
Lớn nhất	282,82	59,18
≤ 5 m	53,3%	63,5%
≤ 8 m	69,5%	80,5%

Bootstrap 10.000 lần (khoảng tin cậy 95%)

- TB V2: 5,36 m (5,02–5,71)
- TB V1: 9,28 m (8,01–10,72)
- Giảm ghép cặp: 3,92 m (2,74–5,30)
- V2 sai ít hơn trên 60,4% fingerprint

Nguồn: Efron, Ann. Statist. 1979 [20]

Version 2 trên các tập WAP của HUIM



- Version 2 giảm sai số với MỌI tập WAP.
- Nhưng tập HUIM vẫn trên 17 m — xa dải 7–8 m.
- Cùng 91 WAP: HUIM union C 19,14 → 17,49 m, top-n theo MI 18,54 → **14,73 m**.
- **Kết luận RQ2 của Version 1 không đổi:** đối chứng đơn giản vẫn chọn WAP tốt hơn HUIM. Cải thiện của V2 đến từ bộ ước lượng toạ độ, không từ HUIM.

So sánh Version 1 và Version 2: số liệu

Chỉ số (validationData)	Version 1	Version 2	Thay đổi
Sai số trung bình (m thực địa)	9,28	5,36	−3,92 m
Sai số trung vị (m thực địa)	4,61	3,52	−1,09 m
Phân vị 90 (m thực địa)	17,02	11,89	−5,13 m
Phân vị 95 (m thực địa)	27,81	16,09	−11,72 m
Sai số lớn nhất (m thực địa)	282,82	59,18	−223,64 m
Sai số TB, m toạ độ chiếu	12,11	6,99	−5,12 m
Tỉ lệ fingerprint sai ≤ 8 m	69,49%	80,47%	+10,98 pp
Độ chính xác tòa nhà	98,74%	99,91%	+1,17 pp
Độ chính xác tầng	87,94%	94,69%	+6,75 pp
Độ chính xác joint (tòa nhà + tầng)	87,76%	94,69%	+6,93 pp
HUIM union C (91 WAP): sai số TB (m)	19,14	17,49	−1,65 m

Cùng 1.111 fingerprint kiểm định; V1 = k-NN k = 1 (S0), V2 = mô hình S4 do giao thức chọn trên dev. Xanh = tốt hơn.

So sánh Version 1 và Version 2: phương pháp & trình bày

Hạng mục	Version 1	Version 2
Bộ ước lượng toạ độ	k-NN k = 1, Manhattan, biểu diễn positive, trọng số đều	exponential + Bray-Curtis, k = 12, w = $1/d^4$, dò lệch ±6 dB, ensemble với positive
Cách chọn tham số	Chia ngẫu nhiên 75/25 trainingData; tiêu chí độ chính xác phân loại	GroupKFold(6) theo USERID; tiêu chí sai số TB theo mét
Phần HUIM (EFIM, 3 mô hình p)	Như nhau	Như nhau (không chạy lại)
Kiểm chứng	Unit test EFIM so với oracle vét cạn	+ 28 phép tính lại HUIM, 24 phép tính lại định vị, Excel tính tay
Công thức	Không ghi nguồn; Model B ghi nhầm là utility nội	Mỗi công thức ghi tác giả / nguồn có DOI đã kiểm tra
Biểu đồ, bảng	Ảnh chụp từ Word/PowerPoint, font khác nhau	Vẽ lại từ results/, in minUtil, mỗi biểu đồ kèm CSV
Định dạng số	Lẫn lộn (87.76% / 19.861 / 19,861)	Thống nhất kiểu Việt Nam: 1.234,56
Số trang	22 trang	38 trang (thêm phần Version 2, so sánh, đính chính, tài liệu)

Đính chính nội dung slide Version 1

Slide V1	Version 1 ghi	Version 2 sửa thành
8	Model B: “internal utility đo bằng mutual information”	MI là **external** utility p(i); q(i,T) dùng chung cho cả 3 mô hình
14	Sắp xếp mục theo TWU giảm dần	Sắp theo TWU **tăng** dần (slide 15 của V1 đã ghi đúng)
14	“Xây dựng cây EFIM: quét CSDL 1 lần để tạo cây”	EFIM không dựng cây dữ liệu; nó duyệt cây liệt kê bằng DFS và chiếu CSDL
14	Xuất tập có utility > minUtil	u(X) **≥** minUtil
16	“19.861 bản ghi kiểm luyện”; “lọc nhiễu, làm đầy RSSI”	19.937 fingerprint huấn luyện (19.861 giao dịch không rỗng); không làm đầy giá trị nào
6	“EFIM chạy trên 19.937 fingerprint”	19.861 giao dịch (76 fingerprint rỗng bị bỏ)
11	“Dòng CSV (dòng 3248)”	Dòng 3.250 của file CSV = chỉ số pandas 3.248
3	“HUIM … nâng cao độ chính xác và ổn định của IPS”	Thực nghiệm cho thấy HUIM KHÔNG thắng đối chứng; nêu như câu hỏi nghiên cứu

Số slide theo bản Version 1 (22 trang).

Kiểm chứng độc lập

Ba lớp kiểm tra không dựa vào mã thí nghiệm — người đọc tự chạy lại được

HUIM

28/28

phép kiểm tra đạt

Tính lại q, p, u(X) từ CSV gốc; kiểm tra mọi HUI của ba lần khai phá chính; vét cạn mọi tổ hợp 1–3 WAP.

`python src/verify_huim.py`

ĐỊNH VỊ

24/24

phép kiểm tra đạt

Tính lại độ chính xác và sai số chỉ bằng thư viện chuẩn của Python; tìm lại láng giềng gần nhất trên toàn bộ trainingData.

`python src/verify_positioning.py --brute 25`

EXCEL

206

ô kiểm tra KHỚP

Công thức Excel tính lại minUtil, utility của HUI và mọi dự đoán của cả hai phiên bản.

`verification/kiem_chung_thu_cong.xlsx`

Mọi con số trên các slide được src/make_deck_v2.py đọc từ results/ lúc dựng slide (không gõ tay); mỗi biểu đồ có file CSV chứa đúng các dòng đã vẽ trong figures/deck_v2/.

Kết luận

- **RQ1 — Mô hình hoá được:** 19.937 fingerprint → 19.861 utility transaction; EFIM chạy 37 cấu hình ngưỡng và khớp oracle vét cạn. “Hợp lý” là hợp lý CỦA ĐỊNH NGHĨA utility, không phải tính chất của dữ liệu.
- **RQ2 — HUIM chưa thắng đối chứng:** HUIM union thua top-n theo MI ở cả ba mô hình (64,99% / 66,79% / 71,56% so với 71,38% / 70,21% / 74,44%); trần tối đa 91 WAP.
- **RQ3 — Chi phí:** số HUI và bộ nhớ khai phá tăng vọt khi hạ minUtil, số WAP gần như đứng yên; thời gian và bộ nhớ định vị giảm gần tuyến tính theo số WAP.
- **RQ4 — Version 2:** sai số trung bình 9,28 → 5,36 m (giảm 3,92 m, KTC 95% 2,74–5,30), joint 87,76% → 94,69%, không dùng tập kiểm định để chọn.
- Model B chọn tập WAP khác Model A (Jaccard 0,528 [21]), nhưng MI gần trùng tần suất phát hiện (ρ = 0,9908).
- **Đóng góp đúng mức:** khảo sát khả năng thích nghi HUIM cho bài toán chọn nhóm AP — có đối chứng, báo cáo cả kết quả âm, không tuyên bố tính mới.

Kết luận và Hướng nghiên cứu tiếp theo



- HUIM mô hình hoá được vân tay Wi-Fi thành dữ liệu giao dịch để chọn nhóm AP.
- Nhưng nhóm AP do HUIM chọn chưa tốt hơn tiêu chí đơn giản (top-n theo MI).
- Sai số định vị giảm 9,28 → 5,36 m nhờ tối ưu bộ ước lượng toạ độ (V2), không nhờ HUIM.
- Hướng tiếp: utility ngoài độc lập với tần suất phát hiện; top-k hoặc closed HUIM để lấy nhiều WAP hơn với cùng ngân sách; thêm một tập kiểm tra chưa từng dùng.

Tài liệu tham khảo (1/2)

[1] R. Agrawal, T. Imieliński, and A. Swami, "Mining association rules between sets of items in large databases," in Proc. ACM SIGMOD, 1993, pp. 207–216. doi:10.1145/170035.170072 †

[2] H. Yao, H. J. Hamilton, and C. J. Butz, "A foundational approach to mining itemset utilities from databases," in Proc. SIAM Int. Conf. Data Mining (SDM), 2004, pp. 482–486. doi:10.1137/1.9781611972740.51 †

[3] W. Gan, J. C.-W. Lin, P. Fournier-Viger, H.-C. Chao, V. S. Tseng, and P. S. Yu, "A survey of utility-oriented pattern mining," IEEE Trans. Knowl. Data Eng., vol. 33, no. 4, pp. 1306–1327, 2021. doi:10.1109/TKDE.2019.2942594 †

[4] Y. Liu, W.-K. Liao, and A. Choudhary, "A two-phase algorithm for fast discovery of high utility itemsets," in Lecture Notes in Computer Science (PAKDD), 2005, pp. 689–695. doi:10.1007/11430919_79 †

[5] S. Zida, P. Fournier-Viger, J. C.-W. Lin, C.-W. Wu, and V. S. Tseng, "EFIM: A fast and memory efficient algorithm for high-utility itemset mining," Knowl. Inf. Syst., vol. 51, no. 2, pp. 595–625, 2017. doi:10.1007/s10115-016-0986-0 †

[6] C. E. Shannon, "A Mathematical Theory of Communication," Bell System Technical Journal, vol. 27, no. 3, pp. 379–423, 1948. doi:10.1002/j.1538-7305.1948.tb01338.x ‡

[7] Y. Chen, Q. Yang, J. Yin, and X. Chai, "Power-efficient access-point selection for indoor location estimation," IEEE Trans. Knowl. Data Eng., vol. 18, no. 7, pp. 877–888, 2006. doi:10.1109/TKDE.2006.112 †

[8] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," Journal of Documentation, vol. 28, no. 1, pp. 11–21, 1972. doi:10.1108/eb026526 ‡

[9] J. Torres-Sospedra, R. Montoliu, S. Trilles, Ó. Belmonte, and J. Huerta, "Comprehensive analysis of distance and similarity measures for Wi-Fi fingerprinting indoor positioning systems," Expert Syst. Appl., vol. 42, no. 23, pp. 9263–9278, 2015. doi:10.1016/j.eswa.2015.08.013 †

[10] C. Spearman, "The Proof and Measurement of Association between Two Things," The American Journal of Psychology, vol. 15, no. 1, pp. 72, 1904. doi:10.2307/1412159 ‡

[11] C. Zhang, G. Almpanidis, W. Wang, and C. Liu, "An empirical evaluation of high utility itemset mining algorithms," Expert Syst. Appl., vol. 101, pp. 91–115, 2018. doi:10.1016/j.eswa.2018.02.008 †

† danh mục đã kiểm tra DOI qua Crossref của dự án (research/papers_table.csv) ‡ kiểm tra DOI qua Crossref ngày 13/10/2026 (research/doi_verification_formulas.json)

Tài liệu tham khảo (2/2)

[12] P. Fournier-Viger et al., "The SPMF open-source data mining library version 2," in Lecture Notes in Computer Science (ECML PKDD), 2016, pp. 36–40. doi:10.1007/978-3-319-46131-1_8 †

[13] J. P. Snyder, "Map projections: A working manual," Professional Paper, 1987. doi:10.3133/pp1395 ‡

[14] S. Adler, S. Schmitt, K. Wolter, and M. Kyas, "A survey of experimental evaluation in indoor localization research," in Proc. IPIN, 2015, pp. 1–10. doi:10.1109/IPIN.2015.7346749 †

[15] A. Khalajmehrabadi, N. Gatsis, and D. Akopian, "Modern WLAN fingerprinting indoor positioning methods and deployment challenges," IEEE Commun. Surveys Tuts., vol. 19, no. 3, pp. 1974–2002, 2017. doi:10.1109/COMST.2017.2671454 †

[16] K. Kaemarungsi and P. Krishnamurthy, "Modeling of indoor positioning systems based on location fingerprinting," in Proc. IEEE INFOCOM 2004, vol. 2, pp. 1012–1022. doi:10.1109/INFCOM.2004.1356988 †

[17] J. R. Bray and J. T. Curtis, "An Ordination of the Upland Forest Communities of Southern Wisconsin," Ecological Monographs, vol. 27, no. 4, pp. 325–349, 1957. doi:10.2307/1942268 ‡

[18] P. Bahl and V. N. Padmanabhan, "RADAR: An in-building RF-based user location and tracking system," in Proc. IEEE INFOCOM 2000, vol. 2, pp. 775–784. doi:10.1109/INFCOM.2000.832252 †

[19] D. Shepard, "A two-dimensional interpolation function for irregularly-spaced data," Proceedings of the 1968 23rd ACM national conference, pp. 517–524, 1968. doi:10.1145/800186.810616 ‡

[20] B. Efron, "Bootstrap Methods: Another Look at the Jackknife," The Annals of Statistics, vol. 7, no. 1, 1979. doi:10.1214/aos/1176344552 ‡

[21] P. Jaccard, "The distribution of the flora in the alpine zone," New Phytologist, vol. 11, no. 2, pp. 37–50, 1912. doi:10.1111/j.1469-8137.1912.tb05611.x ‡

† danh mục đã kiểm tra DOI qua Crossref của dự án (research/papers_table.csv) ‡ kiểm tra DOI qua Crossref ngày 13/10/2026 (research/doi_verification_formulas.json)