High Utility Itemset Mining (HUIM)

HUIM là gì?

High Utility Itemset Mining **(HUIM)** phương pháp tìm các tập mục có **tổng chất lượng cao**, kết hợp tần suất và lợi ích.
Khác với Frequent Itemset Mining chỉ quan tâm tần suất xuất hiện, HUIM ưu tiên giá trị mang lại.

Ví dụ siêu thị

nhiều nước suối –> lợi nhuận thấp trên từng sản phẩm
1 chai nước hoa → lợi nhuận cao

FREQUENT ITEMSET MINING		HIGH UTILITY ITEMSET MINING
Dựa trên số lần xuất hiện	MỤC TIÊU →	Dựa trên tổng utility (lợi ích)
Đếm giao dịch	TIÊU CHÍ →	Tính tổng utility của tập mục
Phổ biến nhưng có thể lợi nhuận thấp	KẾT QUẢ →	Ít phổ biến nhưng lợi nhuận cao
Mua bánh mì & sữa (rất thường xuyên)	VÍ DỤ →	Mua rượu vang & phô mai (ít nhưng lợi nhuận cao)

HUIM và Hệ thống Định vị Trong nhà (IPS)

Wi-Fi fingerprinting ghi nhận cường độ tín hiệu từ nhiều AP tại các vị trí khác nhau.

Số lượng AP lớn nhưng không phải AP nào cũng hữu ích cho định vị.

HUIM giúp chọn các AP có **tổng utility cao**, kết hợp tần suất và lợi ích, nâng cao độ chính xác và ổn định của IPS.

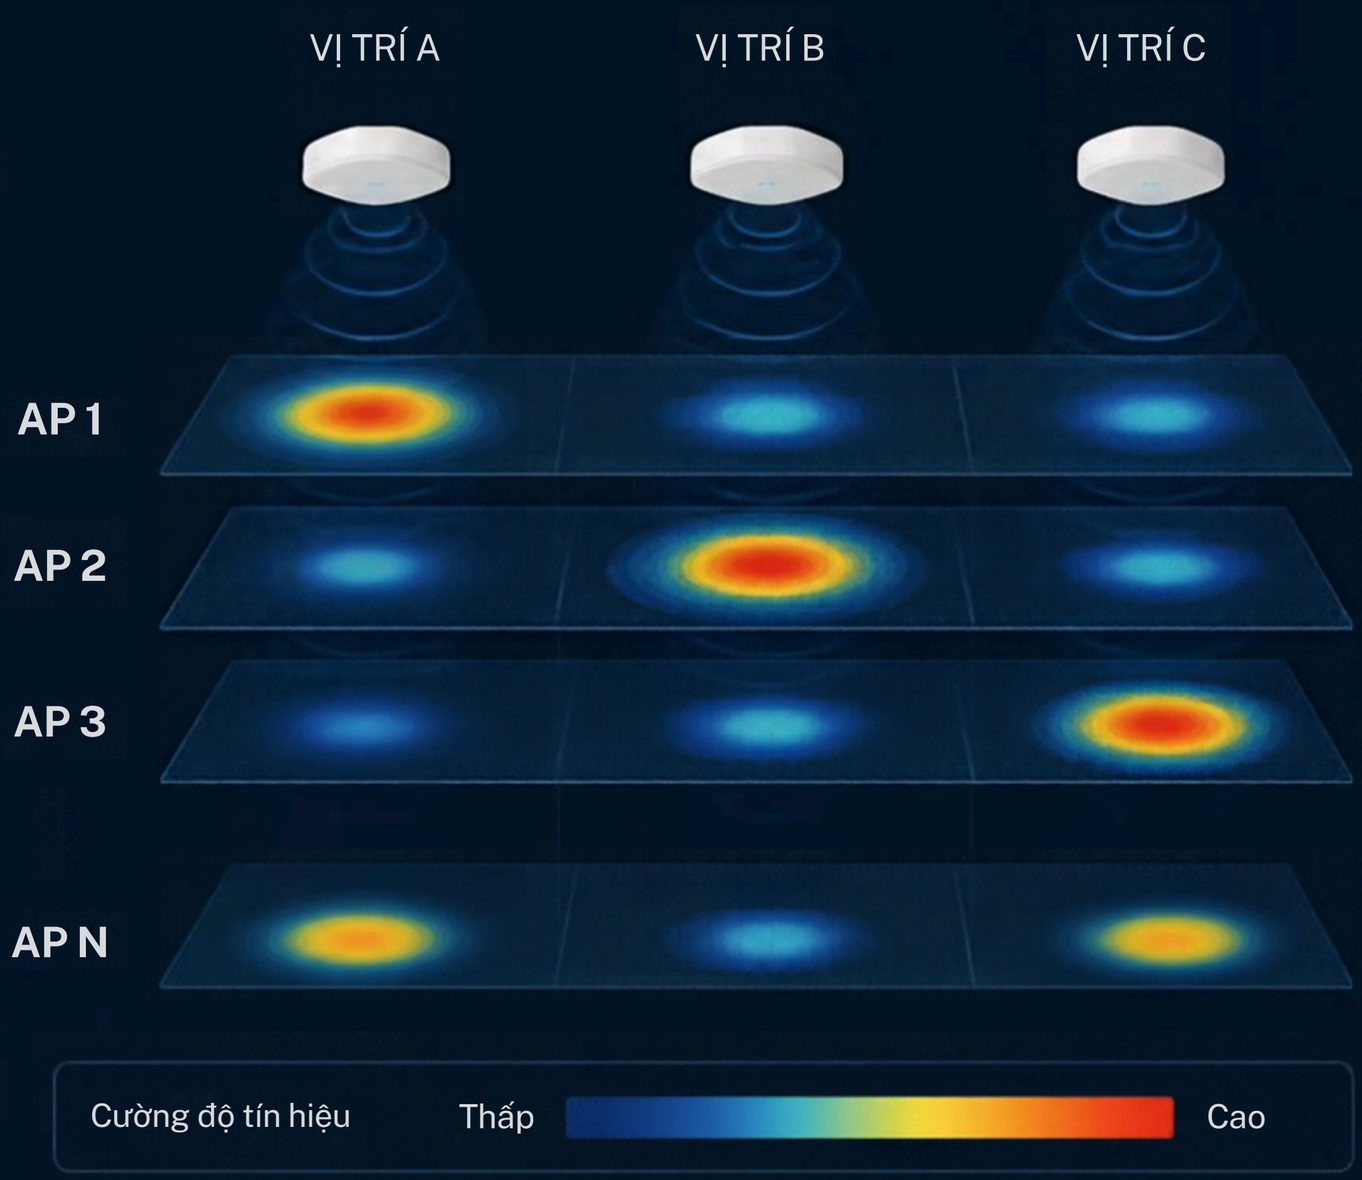

Ba cách định nghĩa p(i)

A

Model A
Signal

$p(i) = 1$

Chỉ nhìn cường độ sóng và mức đồng xuất hiện

Đối chứng

B

Model B
Discriminative

$p(i) = I(WAP_i ; tầng) / \max I$

WAP nào giúp biết đang ở tầng nào thì có giá trị cao

Model chính

C

Model C
Rare-discriminative

$p(i) \propto I(WAP_i ; tầng) \times \log(N / (1+support))$

Như B, nhưng phạt WAP có mặt ở khắp nơi

Biến thể thứ ba

Trong HUIM, mỗi phần tử có một giá trị utility và thuật toán sẽ tìm những tập phần tử có tổng utility đạt một ngưỡng gọi là minUtil.

– Model A (signal): 8 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 2.5%
– Model B (discriminative): 4 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 5%
– Model C (rare-discr.): 6 lần chạy cho 0 HUI; HUI đầu tiên xuất hiện ở 3.5%
– Chuyển pha rất gắt: từ 'không có gì' sang 'vượt ngân sách' chỉ trong một bước ngưỡng.
– Số HUI khổng lồ nhưng chỉ đến từ vài chục WAP riêng biệt.

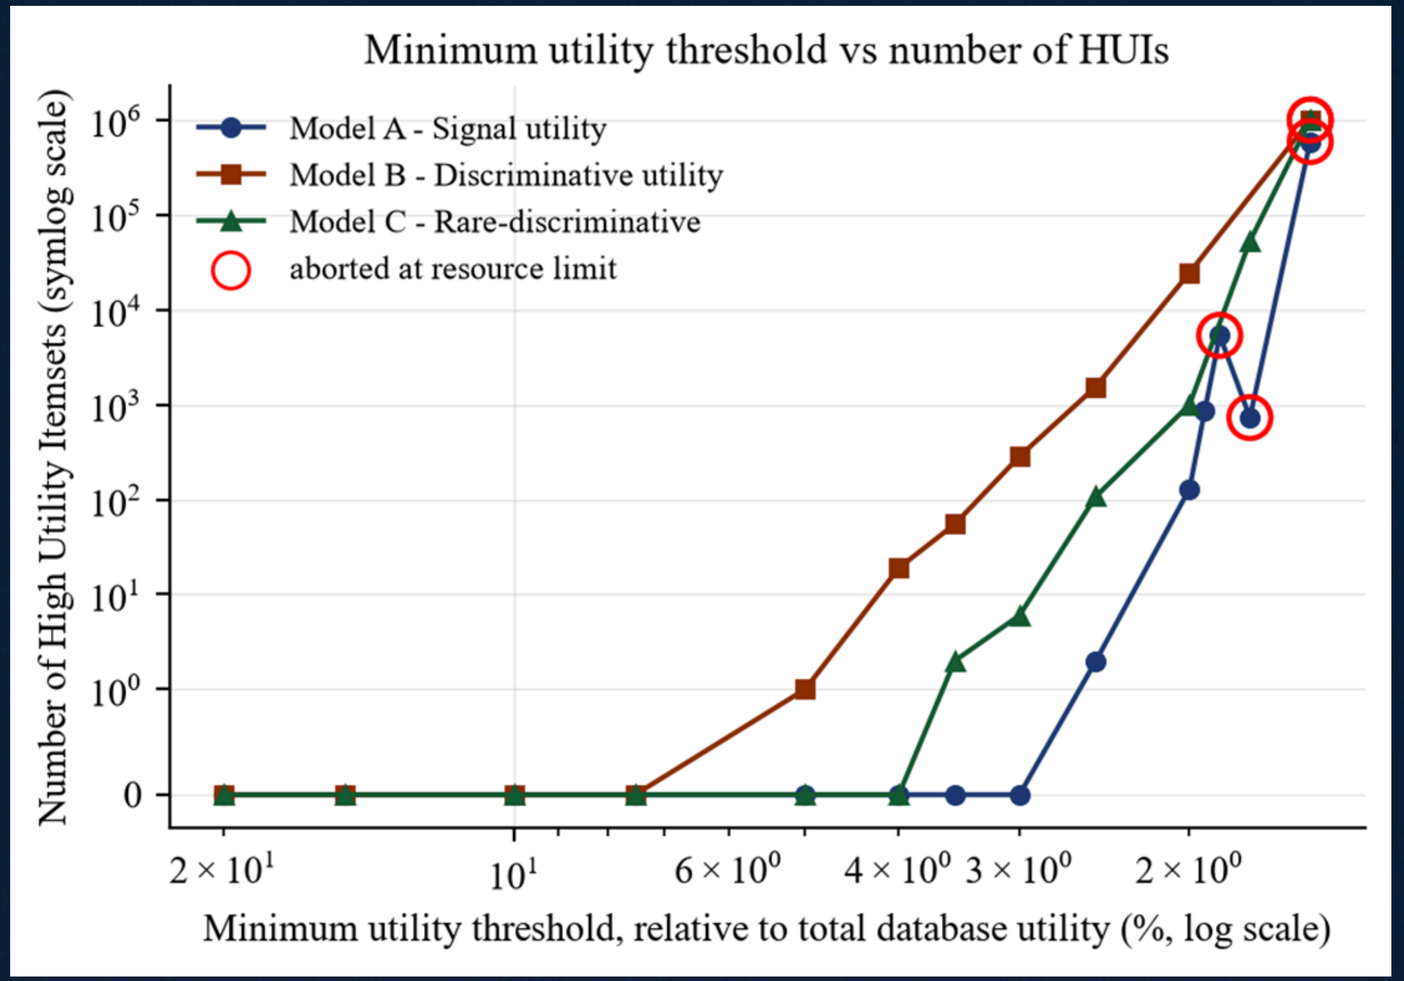

p(i) quyết định chi phí khai phá

Cùng ngưỡng minUtil = 2% tổng utility, EFIM chạy trên 19.937 fingerprint

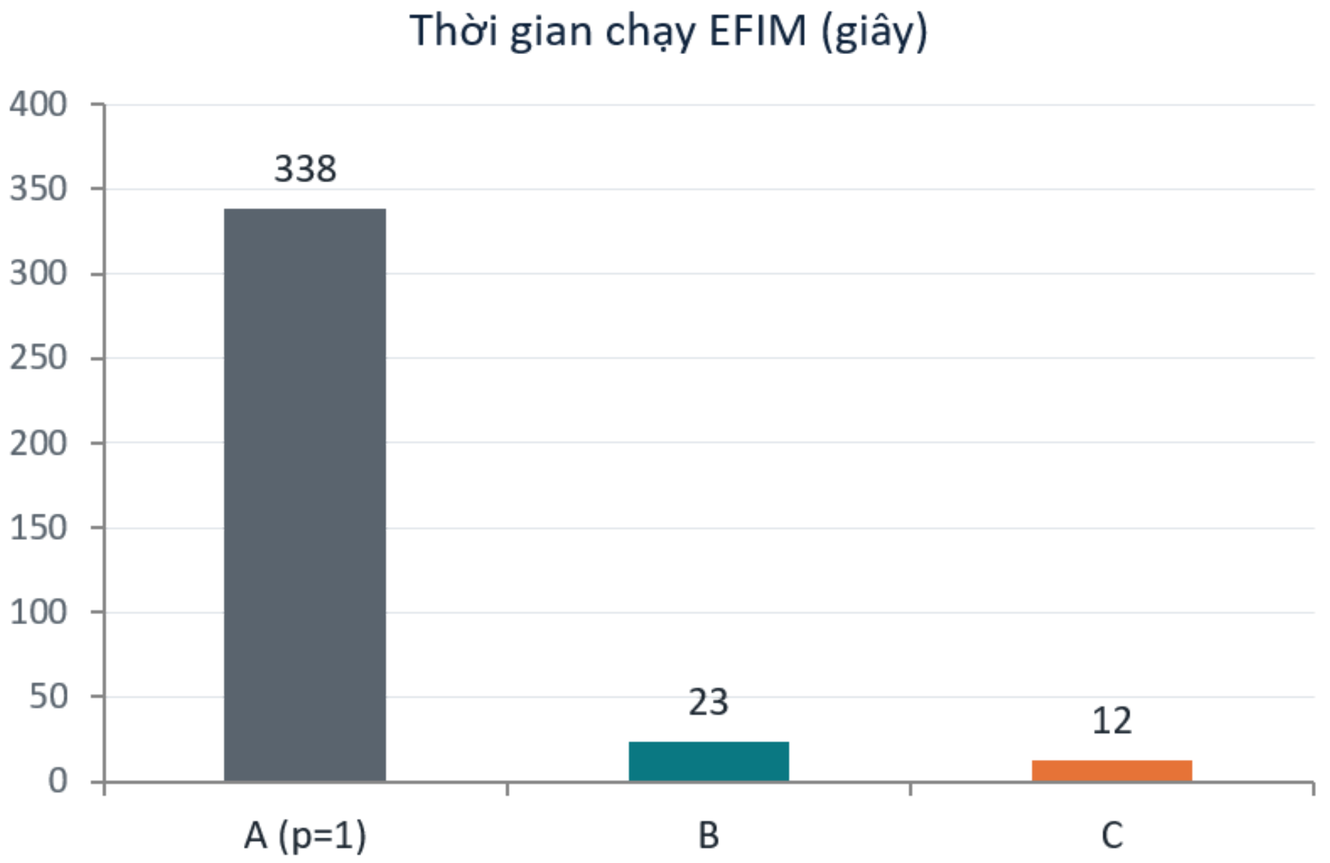

14–27×

Model A chậm hơn B và C

130 vs 24.621

Số HUI của A so với B. A có ít HUI hơn nhưng vẫn chậm hơn, vì p = 1 làm các cận trên cắt tỉa kém

Runtime và bộ nhớ theo ngưỡng

–Model A (signal): runtime 0.10–600.89 s, bộ nhớ đỉnh 0.6–354.7 MB, 3 lần ABORTED.

–Model B (discriminative): runtime 0.23–23.29 s, bộ nhớ đỉnh 0.0–492.8 MB, 1 lần ABORTED.

–Model C (rare-discr.): runtime 0.19–99.17 s, bộ nhớ đỉnh 0.0–518.9 MB, 1 lần ABORTED.

–Spearman ρ(số nút cây đã duyệt, runtime) = 0.995, 0.973, 0.998 → chi phí là chi phí TRÊN MỖI NÚT.

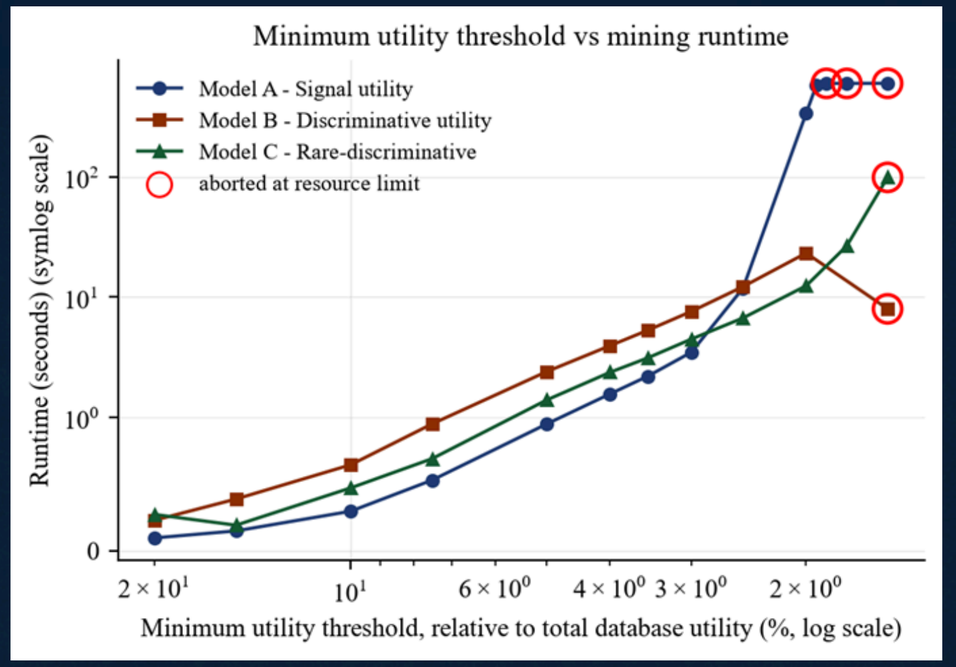

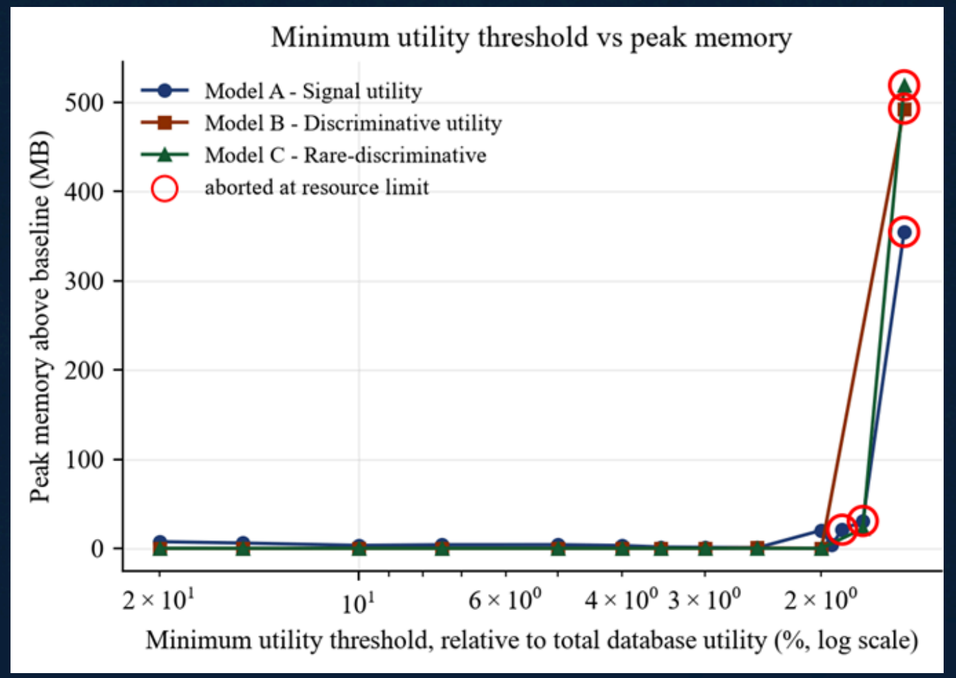

Mô hình hóa Utility trong IPS

GIAO DỊCH
một lần quét Wi-Fi (fingerprint)

→

ITEM
một Access Point (AP)

→

UTILITY
internal utility x external utility (chuẩn hóa RSSI x độ quan trọng AP)

→

HUIM
khai thác tập mục utility cao, tần suất và lợi ích cao

BA MÔ HÌNH UTILITY ỨNG DỤNG CHO WI-FI FINGERPRINTING

MODEL A
DỰA TRÊN RSSI

internal utility là cường độ RSSI chuẩn hóa theo từng lần quét

MODEL B
DỰA TRÊN MUTUAL INFORMATION

internal utility đo bằng mutual information giữa AP và vị trí

MODEL C
KẾT HỢP MI VÀ ĐỘ HIỂM

kết hợp mutual information và độ hiểm của AP

MỤC TIÊU: đánh giá và khai thác các tập AP có tổng utility cao, xuất hiện đủ thường xuyên, mang lại lợi ích lớn để tăng độ chính xác và ổn định của hệ thống định vị trong nhà dùng Wi-Fi.

Tổng quan: 5 bước tiền xử lý

Từ một dòng CSV đến đầu vào của thuật toán EFIM

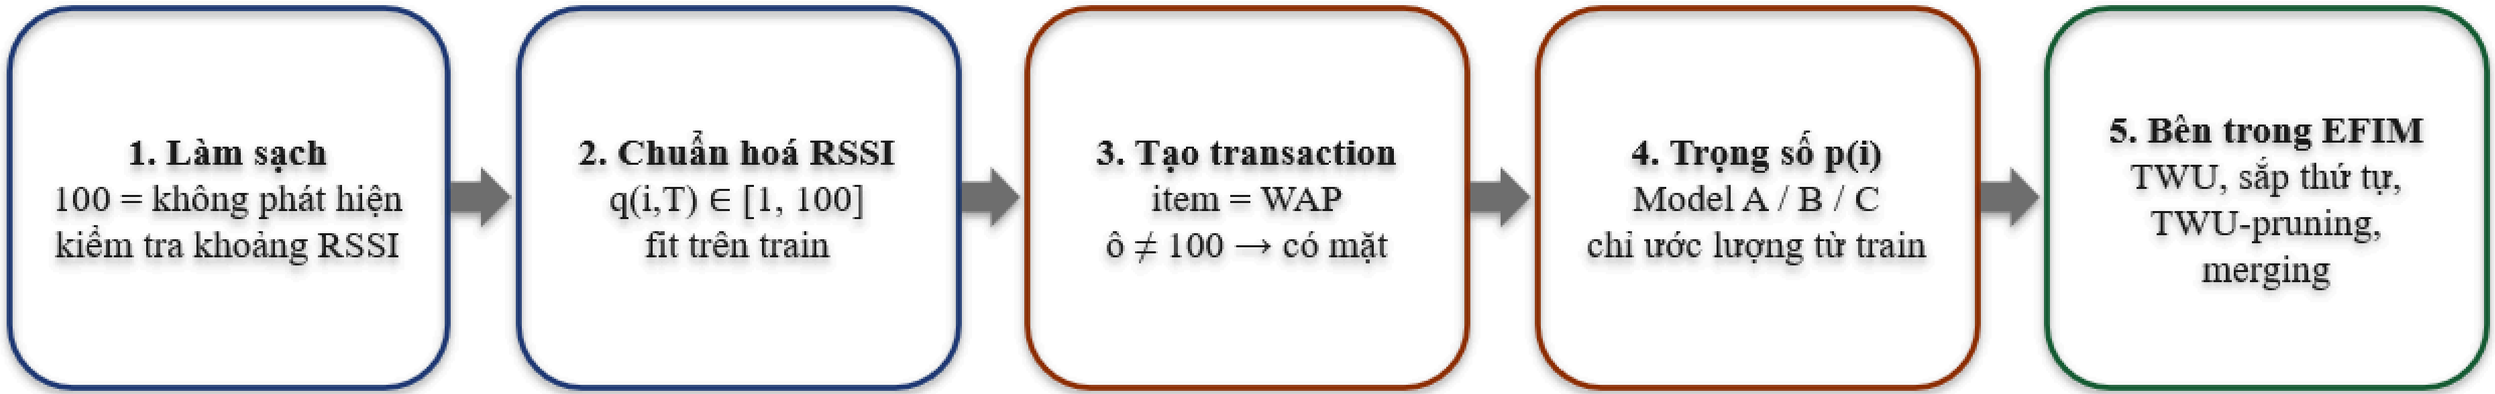

- Đầu vào: trainingData.csv (19.937 dòng) và validationData.csv (1.111 dòng), mỗi file 520 cột WAP.
- Đầu ra: danh sách transaction {WAP: q} và vector p(i) cho từng WAP.
- Mọi tham số học từ dữ liệu (RSSI min/max, p(i)) chỉ lấy từ trainingData.

Bước 1: chuẩn hoá RSSI sang “positive representation”

Không phát hiện (100) → 0 (“không có thông tin”).

• Đã phát hiện: đưa RSSI về [0,1] theo min/max của train, rồi ánh xạ sang [1, 100].

• Làm tròn thành số nguyên dương; không bao giờ để ô đã phát hiện làm tròn về 0.

• Kết quả q(i,T) là số nguyên dương → EFIM cần utility dương cho các cận trên.

• Q_MAX = 100 là lựa chọn để dễ đọc, không phải siêu tham số được tinh chỉnh.

Công thức

$$q = \text{round}(\ 1 + (RSSI - RSSI_min) / (RSSI_max - RSSI_min) \times 99\ )$$

Tham số fit trên train: RSSI_min = −104, RSSI_max = 0 (n = 19.937 dòng)

WAP	RSSI thô	q(i,T)
WAP255	−77	27
WAP284	−89	15
WAP310	−78	26
WAP366	−78	26

fit_preprocessor kiểm tra khoảng RSSI phát hiện nằm trong [−104, 0], nếu không sẽ báo lỗi.

Bước 2: mỗi fingerprint thành một utility transaction

Dòng CSV (dòng 3248)
520 cột WAP
4 cột ≠ 100, 516 cột = 100

→

Transaction
{WAP255: 27, WAP284: 15,
WAP310: 26, WAP366: 26}

→

Sau khi có p(i)
Model A: tổng utility = 94
Model B: tổng utility ≈ 15,5

Thống kê (trainingData)	Giá trị
Số dòng / transaction	19.937
Transaction không rỗng	19.861
Transaction rỗng (76 dòng không phát hiện AP nào)	76
Độ dài trung bình (không rỗng)	18,06
Số item khác nhau thực sự xuất hiện	465 / 520

- 76 dòng rỗng tập trung ở vài thiết bị (PHONEID 22: 14, PHONEID 1: 59…) — nghi lỗi thu thập; vẫn giữ cho bộ phân lớp để mọi điều kiện thấy cùng dữ liệu.
- Không có AP nào xuất hiện trong hơn 23,8% fingerprint.

Bước 3: external utility p(i): 3 mô hình

Mô hình	p(i)	Vai trò
A – Signal	p(i) = 1 với mọi WAP	Điều kiện đối chứng
B – Discriminative	max(I(A_i;Y), 1e-6) / max_j I(A_j;Y)	Mutual information với nhãn BUILDINGID_FLOOR
C – Rare-discriminative	I(A_i;Y) × log(N / (1 + support_i)), chuẩn hoá về (0,1]	Giảm trọng số AP xuất hiện khắp nơi

- Y = BUILDINGID_FLOOR (13 lớp, H(Y) = 3,639 bit). SPACEID bị loại vì bằng 0 toàn bộ trong validationData.
- I(A;Y) tính từ histogram đồng thời với 6 trạng thái: 1 "không phát hiện" + 5 khoảng dBm, biên [−104, −90, −80, −70, −60, 0].
- Model B: p_mean = 0,175; AP tốt nhất WAP087 (0,438 bit). Model A: tổng utility của DB = 9.058.242.
- Sàn 1e-6 giữ p > 0 vì EFIM yêu cầu utility dương.

Từ fingerprint Wi-Fi đến bài toán HUIM

Fingerprint không có sẵn q và p, nên phải tự định nghĩa

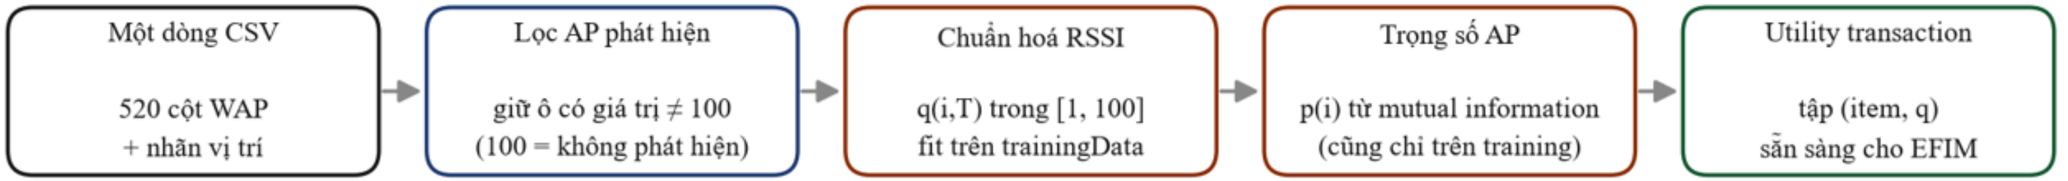

Item	Transaction	q(i,T)	p(i)	HUI
Một WAP	Một lần đo	RSSI chuẩn hoá 1..100	**Cần định nghĩa: Model A, B, C**	Nhóm WAP utility cao

Chỉ thay p(i), giữ nguyên mọi thứ khác: cùng dữ liệu, cùng q, cùng EFIM, cùng k-NN.

Thuật toán EFIM

Khai thác tập mục có tổng utility cao hiệu quả hơn

01

Tiền xử lý

Tính TWU và sắp xếp mục theo TWU giảm dần

02

Xây dựng cây EFIM

Quét CSDL 1 lần để tạo cây nên theo thứ tự TWU

03

Khai thác đệ quy theo DFS

Duyệt cây và mở rộng các tập mục tiêm năng

04

Tính utility

Tính utility chính xác cho tập mục sinh ra

$$u(X)$$

$$= \Sigma \text{ utility}(X, T)$$

05

Xuất kết quả

Xuất các tập mục có utility > minUtil

HUIs

TỐI ƯU EFIM

CẮT NHÁNH THÔNG MINH

Sử dụng Local Utility và Subtree Utility để loại bỏ nhánh không thể đạt ngưỡng minUtil sớm

GỘP GIAO DỊCH TƯƠNG ĐỒNG

Gộp các giao dịch có cùng hậu tố để giảm kích thước cây và số phép tính

Tiền xử lý bên trong EFIM

Chạy ở đầu mỗi lần khai phá, trước khi tìm kiếm theo chiều sâu

1. Kiểm tra mọi p(i) > 0 và q > 0; thiếu thì báo lỗi.
2. Tính TU(T) = Σ q·p cho mỗi transaction, TWU(i) = tổng TU của các transaction chứa i.
3. TWU-pruning: bỏ item có TWU < minUtil.
4. Sắp item theo TWU tăng dần (bằng nhau thì theo nhãn).
5. Dựng DB đã cắt tỉa, bỏ transaction rỗng, gộp transaction giống hệt nhau (transaction merging, có cộng dồn count).
6. Tính local utility / subtree utility cho gốc bằng Fast Utility Counting.

minUtil	A: item còn lại	B: item còn lại
20%	17	41
10%	56	60
5%	151	93
2,5%	231	175
2%	250	204

minUtil tính theo % tổng utility của DB. Ngưỡng càng cao thì TWU-pruning càng loại nhiều item; trong 465 item ban đầu, ở minUtil 20% chỉ còn 17 (A) và 41 (B).

Thực nghiệm trên bộ dữ liệu UJIIndoorLoc

19.861
bản ghi kiểm luyện

1.111
bản ghi kiểm định

520
đặc trưng Wi-Fi

QUY TRÌNH THỰC NGHIỆM

01
TIỀN XỬ LÝ RSSI
Lọc nhiễu, chuẩn hóa và làm đầy RSSI

→

02
CHUYỂN ĐỔI FINGERPRINT
Chuyển fingerprint thành utility transaction

→

03
KHAI PHÁ HUIM VỚI EFIM
Khai thác tập mục có tổng utility cao

→

04
XÂY DỰNG MÔ HÌNH
Xây mô hình dự đoán tòa nhà, tầng

→

05
ĐÁNH GIÁ HIỆU NĂNG
Đánh giá độ chính xác dự đoán tòa nhà và tăng

KẾT QUẢ | Độ chính xác dự đoán tòa nhà và tăng được đánh giá trên tập kiểm định.

HUIM có hơn các đối chứng không?

Độ chính xác joint (tòa nhà + tầng) trên validationData, cùng số WAP; baseline 520 WAP = 87,76%

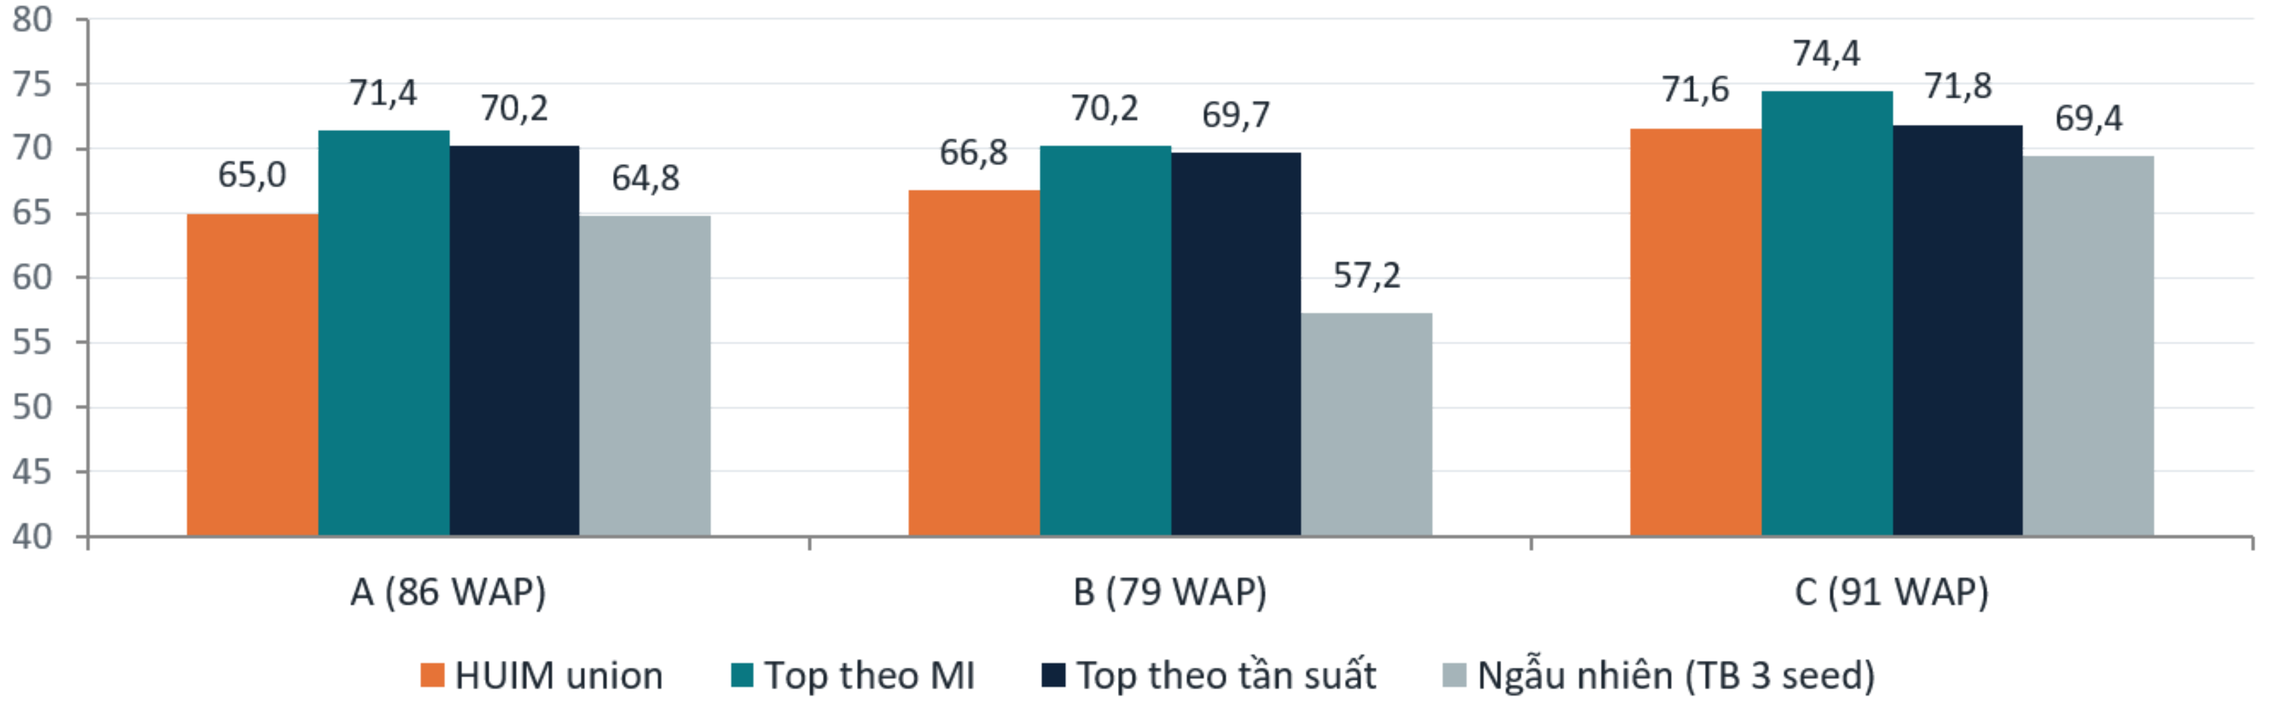

Kết luận trung thực: HUIM thắng ngẫu nhiên ở B và C, nhưng thua Top-MI ở cả ba model. Giá trị là giảm ~82–85% số WAP; mọi cách chọn đều thấp hơn dùng đủ 520 WAP.

Kết quả và Phân tích

Độ chính xác định vị theo mét

Nhận xét

–Baseline: trung vị 6.02 m toạ độ chiếu = 4.61 m thực địa; trung bình 12.11 m chiếu = 9.28 m thực địa.

–Trung vị DƯỚI dải 7–8 m; trung bình TRÊN dải, vì phân bố có đuôi dài (p95 = 27.8 m).

–Toạ độ là EPSG:3857 Web Mercator — xác định bằng cách nghịch đảo phép chiếu, rơi cách campus UJI 139.7 m (UTM lệch hàng trăm km).

–Web Mercator KHÔNG bảo toàn khoảng cách: hệ số 1.305268 → khoảng cách đọc thẳng từ cột toạ độ lớn hơn thực tế ~30%.

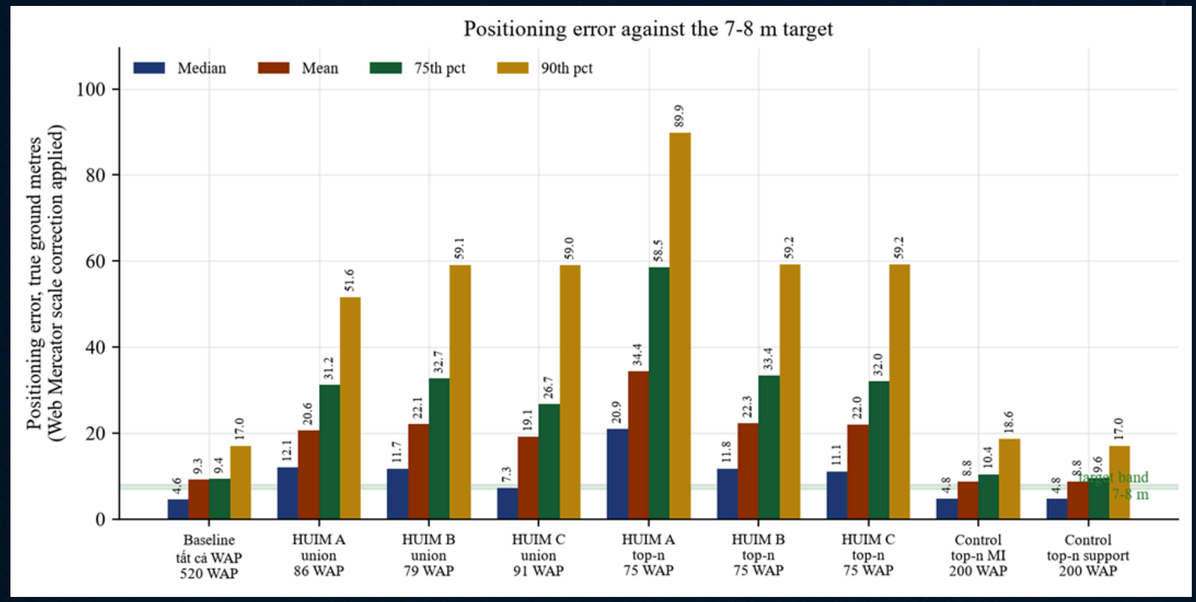

Kết quả và Phân tích

Đánh giá thời gian và bộ nhớ

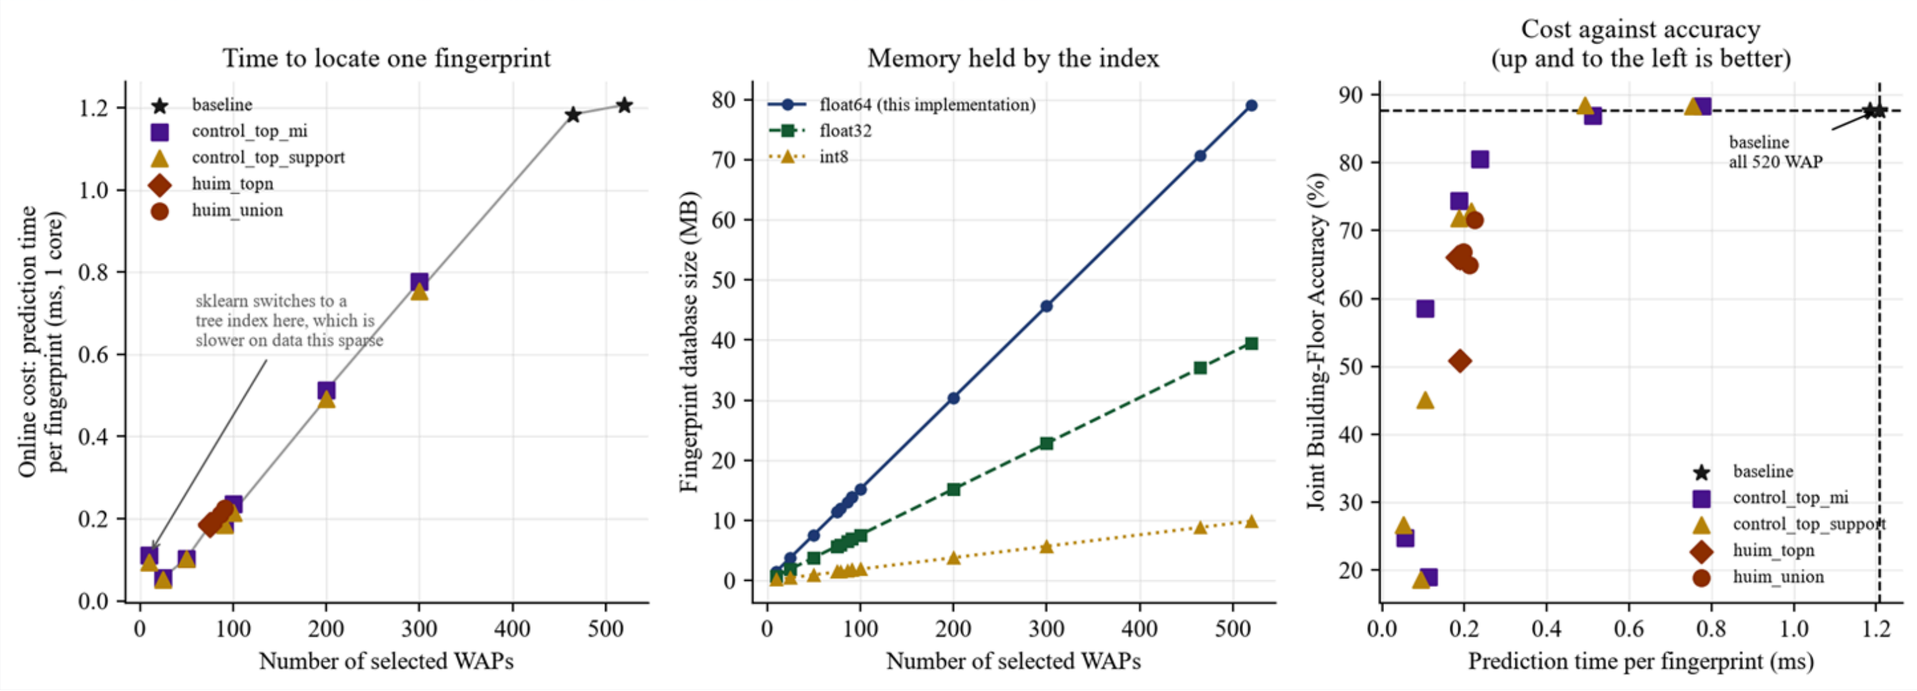

Nhận xét

–Baseline 520 WAP: 1.207 ms/fingerprint, CSDL vân tay 79.1 MB.

–control_top_support__n200 (200 WAP): 0.491 ms/fp (2.5× nhanh hơn), 38% bộ nhớ, và joint accuracy 88.48% (+0.72 pp).

–HUIM tốt nhất (91 WAP): 5.4× nhanh hơn, 18% bộ nhớ, nhưng accuracy 71.56%.

–Đo một lõi, lặp lại lấy trung vị; bộ nhớ CSDL tính chính xác (dòng × cột × kích thước phần tử), không ước lượng.

Feature Reduction và Accuracy

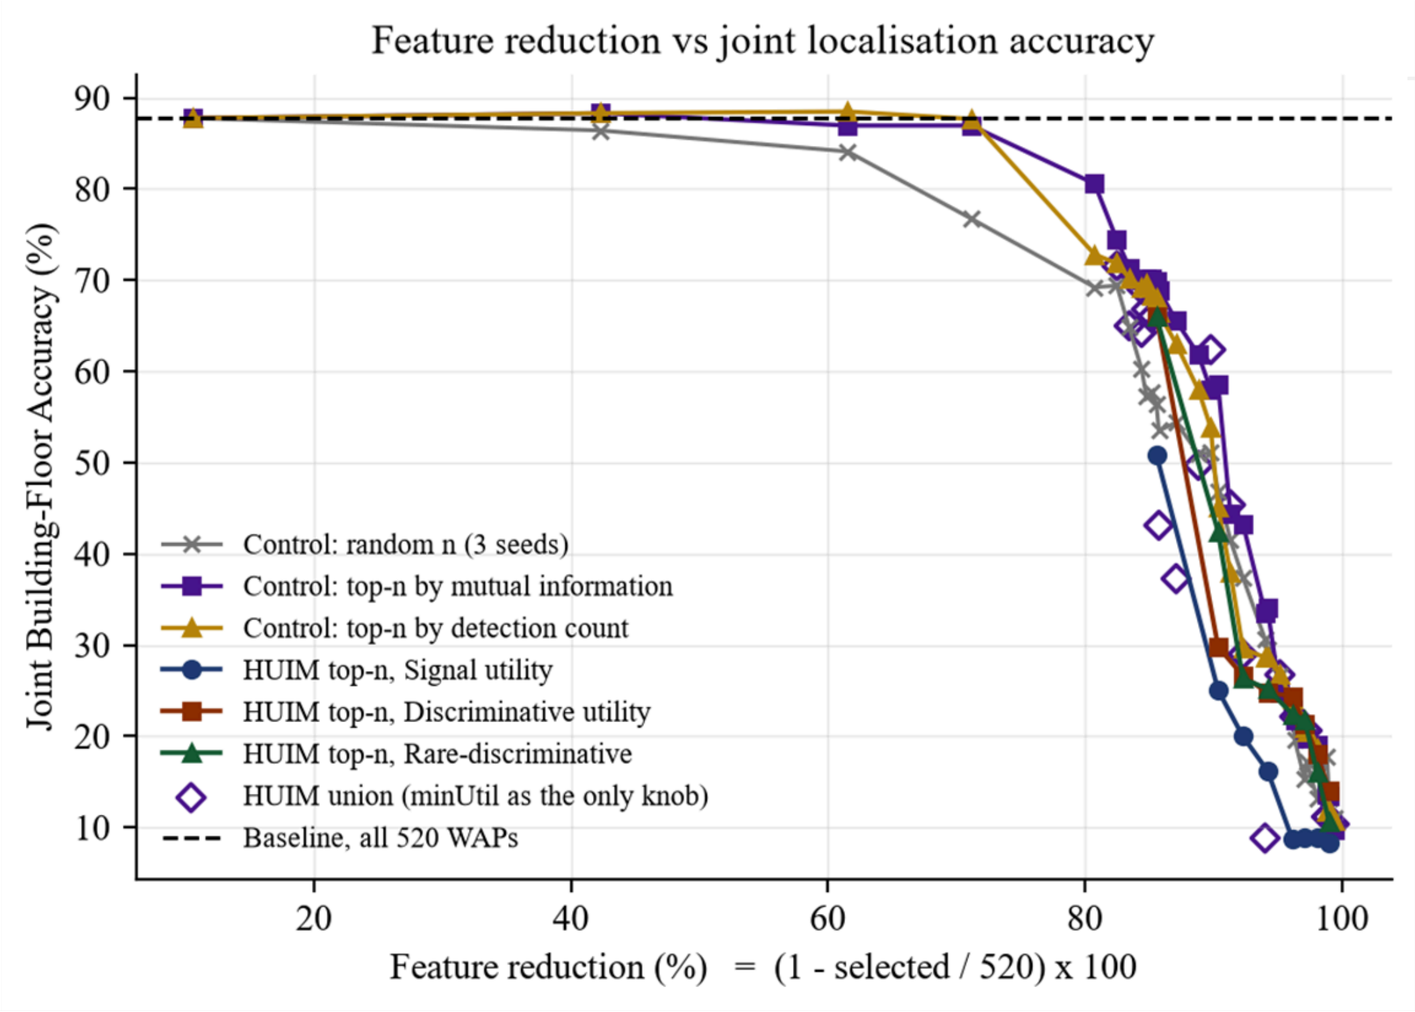

- KHÔNG tập con nào do HUIM chọn đạt được Joint accuracy của baseline toàn bộ WAP.

- Building accuracy chịu được giảm chiều mạnh; Floor accuracy là ràng buộc chặt.

- Hình thoi = điểm union, nơi minUtil là núm điều khiển duy nhất.

Kết luận

–HUIM áp dụng được về mặt kỹ thuật: 19,861 utility transaction, EFIM chạy và cho kết quả; nhưng 'hợp lý' là hợp lý CỦA ĐỊNH NGHĨA utility, không phải tính chất của bộ dữ liệu.

–Discriminative utility (Model B) cho đường cong ngưỡng mượt hơn và chọn tập AP khác Model A (Jaccard 0.528 cho cặp đầu tiên).

–Giảm chiều: không cấu hình HUIM nào đạt baseline 87.76% (520 WAP); trade-off có thật nhưng không thuận lợi.

–CƠ CHẾ: tập AP lớn nhất HUIM tạo ra là 91 WAP. Ở ngân sách đó, MỌI phương pháp đều chỉ đạt tối đa 74.44%, trong khi cần 200 WAP mới chạm baseline — ngay cả một xếp hạng hoàn hảo cũng không thể lấp khoảng cách từ bên trong trần đó.

–ĐỐI CHỨNG: Model A (signal) vượt ngẫu nhiên 0/8; Model B (discriminative) vượt ngẫu nhiên 5/8; Model C (rare-discr.) vượt ngẫu nhiên 3/8; HUIM tốt nhất vượt top-n theo MI 3/8.

–Đóng góp: khảo sát khả năng thích nghi HUIM cho bài toán chọn nhóm AP — có đối chứng, có thể cho kết quả âm, không tuyên bố novelty.

Kết luận và Hướng nghiên cứu tiếp theo

HUIM mô hình hóa Wi-Fi fingerprint thành dữ liệu giao dịch để chọn đặc trưng

EFIM hiệu quả trong khai thác nhóm AP hữu ích

Hiệu quả định vị phụ thuộc vào cách định nghĩa utility và bước chọn AP sau khai thác

Hướng nghiên cứu: cải thiện hàm utility, nghiên cứu Top-k hoặc Closed HUIM để giảm bùng nổ kết quả